Best Model Overview

Ingreso predicho por persona + LightGBM | Equipo 06, MECA 4107

Universidad de los Andes

[pendiente]

F1 público en Kaggle

0,782

F1 en holdout, IC 95 % [0,774; 0,789]

0,776

F1 en CV repetida (15 evaluaciones)

Especificación

- **Variable clave:** el ingreso de cada persona, predicho con lo que el test sí trae y sumado al hogar (1.324 variables en total).
- **Algoritmo:** LightGBM (76 %) mezclado con dos redes (19 %) y un rediseño desde cero (5 %); pesos elegidos fuera de muestra.
- **Regla:** pobre si $P(\text{pobre}) \geq 0{,}36$.

Mensajes

1. Las variables aportaron **9 veces más** F1 que los algoritmos.
2. El techo ($\approx 0{,}78$) viene sobre todo de la información que falta.
3. Excluye al 18 % de los pobres, casi todos cerca de la línea.

F1: media armónica de precisión y recall de la clase pobre. Holdout: 20 % del train nunca usado para decidir. Fuente: views/tablas/nivel7/etapa18_resumen.csv.

El test no trae ingresos: hay que inferir la pobreza sin ver su definición

Universidad de los Andes

Intuición. Un hogar es pobre si su ingreso per cápita está bajo la línea de pobreza de su ciudad y mes. El test no trae ningún ingreso.

- 79 variables solo existen en train, entre ellas todos los ingresos.
- Pobre $\Leftrightarrow$ ingreso per cápita $<$ línea, sin excepciones.
- Bogotá está en train pero no en test.

Métrica. "Nadie es pobre" acierta en el 80 % de los hogares, pero tiene F1 $= 0$. El F1 combina **filtración** (no pobres atendidos) y **subcobertura** (pobres excluidos).

164.960

hogares en train

66.168

hogares en test

20,0 %

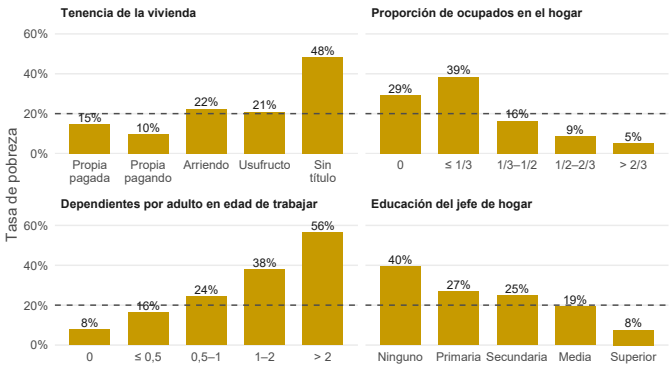
hogares pobres

El problema es reconstruir el ingreso con lo que sí se observa.

Fuente: views/tablas/nivel7/forense_resumen.csv; views/tablas/desbalance_clases.csv.

La teoría acierta: trabajo, dependencia, educación y vivienda predicen la pobreza

Tasa de pobreza en train (164.960 hogares). Línea punteada: promedio (20,0%)



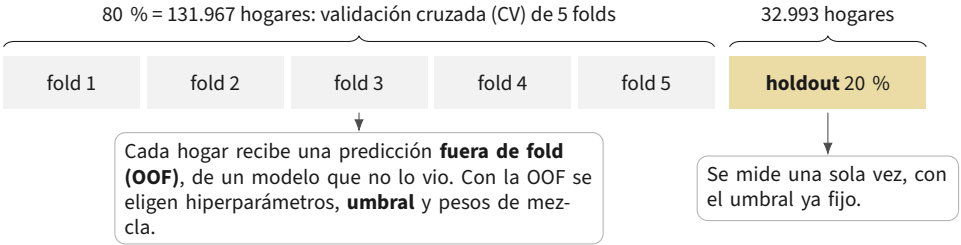
Ingreso per cápita = cuántos trabajan × cuánto gana cada uno ÷ cuántos comen.

- Más dependientes por adulto: pobreza de 8 % a 56 %.
- Jefe sin educación 40 %; con superior 8 %.
- Sin ocupados (29 %) es menos pobre que un tercio ocupado (39 %): pensiones y rentas.

Ninguna variable sola basta: la mejor regla de una variable da F1 de 0,473.

Fuente: base de hogares de train (scripts/13_figuras_presentacion.R); views/tablas/leaderboard_interno.csv.

Confiamos en el holdout porque nunca se usó para decidir

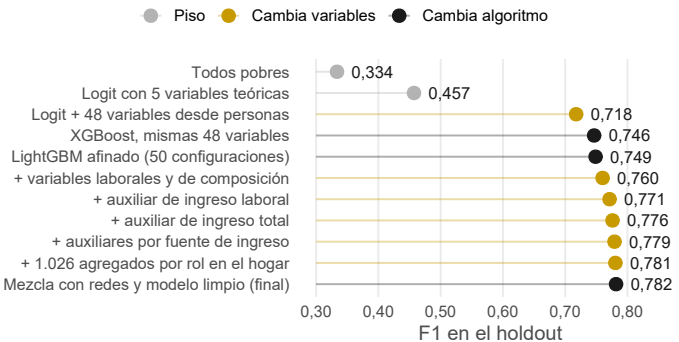


CV repetida: al final repetimos la CV con 3 particiones nuevas (15 evaluaciones) y comparamos modelos con intervalos de confianza (IC: rango de valores compatibles con los datos) pareados por fold y por remuestra del holdout.

La CV repetida reproduce la original casi al milésimo: 0,7752 frente a 0,7748.

Fuente: views/tablas/resumen_particion.csv; views/tablas/nivel7/etapa16_fase1_resumen.csv.

Las variables aportaron 9 veces más F1 que el cambio de algoritmo



Suma de los saltos

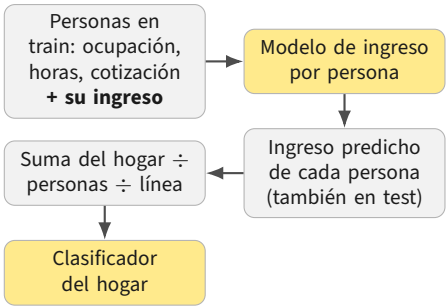
- **Variables**: $+0{,}292$.
- **Algoritmo**: $+0{,}032$.

El salto mayor ($0{,}457 \rightarrow 0{,}718$) es el mismo Logit con variables construidas desde las personas.

Rinde más entender el hogar que cambiar de algoritmo.

F1 en holdout. Fuente: views/tablas/leaderboard_interno.csv y nivel7/ (ablacion_etapa1, resumen_etapa2, etapa6_ablacion, etapa7_a, etapa18_resumen).

El salto clave: predecir el ingreso de cada persona y sumarlo al hogar



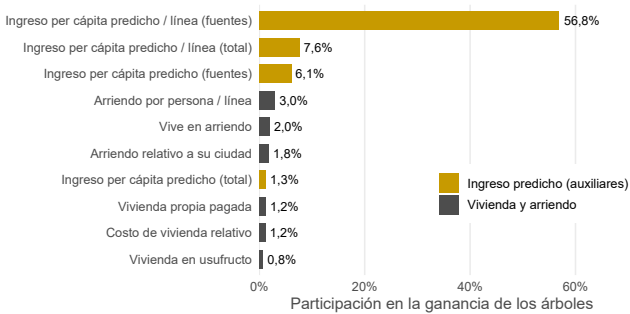
LightGBM con…	F1 holdout	Δ
sin auxiliares	0,760	
+ ingreso laboral	0,771	+0,011
+ ingreso total	0,776	+0,005
+ ingreso por fuente	0,779	+0,003

OOF anidada: el modelo de ingreso que alimenta a un hogar no vio ese hogar ni su fold de validación.

El ingreso de train se usa como objetivo auxiliar, nunca como predictor.

Fuente: views/tablas/nivel7/ablacion_etapa1.csv, resumen_etapa2.csv, etapa6_ablacion.csv.

El modelo decide con el ingreso predicho y con la vivienda



Familia	Vars.	Ganancia
Ingreso predicho	17	75,6 %
Vivienda y arriendo	15	11,2 %
Agregados por rol	1.026	9,1 %
Resto	266	4,0 %

En un boosting interpretable (EBM), la interacción más fuerte es arriendo por persona × vivienda propia pagada.

El modelo reconstruye el ingreso y lo ajusta por el costo de la vivienda.

Ganancia: reducción de la pérdida atribuida a cada variable en LightGBM (76 % de la mezcla). Fuente: views/tablas/nivel7/etapa7_a_importancia.csv, etapa15_ebm_importancia.csv.

Los hiperparámetros importaron poco; el desbalance, nada

LightGBM: 50 configuraciones (hipercubo latino), CV de 5 folds

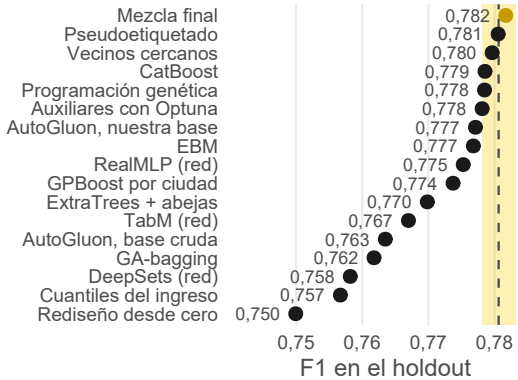
Hiperparámetro	Valor	Lectura
Rondas × tasa	1.852 × 0,011	aprende despacio
Hojas por árbol	31	árboles pequeños
Mínimo por hoja	171 hogares	no memoriza
Variables por corte	82 %	algo de azar
Hogares por árbol	70 %	algo de azar

- Reafinar con 75 intentos (Optuna) sobre las variables nuevas da el mismo F1: 0,7759 frente a 0,7760.
- Promediar 5 semillas cambia el F1 en menos de 0,002.
- **Desbalance:** SMOTE, submuestreo y pesos de clase dan 0,745, 0,747 y 0,744, frente a 0,746 sin balancear. Solo mueven el umbral óptimo (0,36 → 0,66 con pesos).

Elegir el umbral con OOF ya corrige el desbalance; rebalancear no agrega información.

F1 en holdout. Fuente: views/tablas/leaderboard_interno.csv; views/tablas/nivel7/resumen_etapa2.csv.

Dieciséis alternativas chocan con el mismo techo



Efecto mínimo detectable: la mejora más pequeña que el holdout distingue del ruido es $\pm 0{,}0025$ (banda amarilla alrededor de LightGBM base, línea punteada).

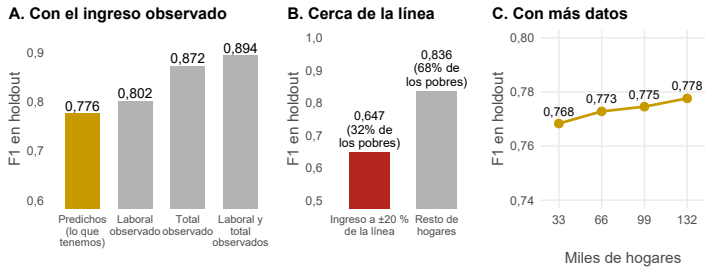
- Ningún algoritmo nuevo supera a LightGBM.
- La mezcla final gana $+0{,}0007$ en CV repetida, IC 95 % $[+0{,}0002; +0{,}0012]$. Corrigiendo por la dependencia entre folds, el IC incluye cero.

Las mejoras posibles están por debajo de lo que los datos permiten detectar.

F1 en holdout. Fuente: views/tablas/nivel7/ (etapa7_b, etapa8 a etapa18); efecto mínimo de etapa16_fase1_resumen.csv.

El techo está en los datos: sin el ingreso, un tercio de los pobres es indistinguible

Universidad de los Andes



A. Con el ingreso observado, el mismo modelo llegaría a 0,87–0,89.

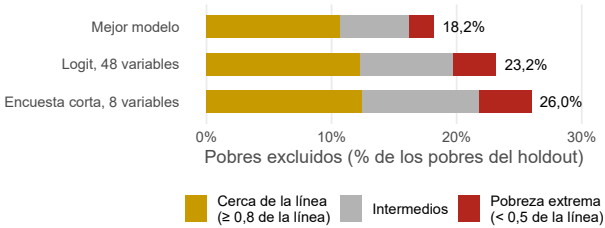
B. El 32 % de los pobres está a $\pm$ 20 % de la línea; ahí el F1 es 0,647.

C. Cuadruplicar los datos sube el F1 solo 0,009.

El límite viene sobre todo de la información que falta: el ingreso.

Versión previa del modelo (LightGBM con auxiliares laboral y total), holdout. Fuente: views/tablas/nivel7/techo_oraculo.csv, techo_bandas.csv, techo_curva_aprendizaje.csv.

Excluimos al 18 % de los pobres, sobre todo a los más cercanos a la línea

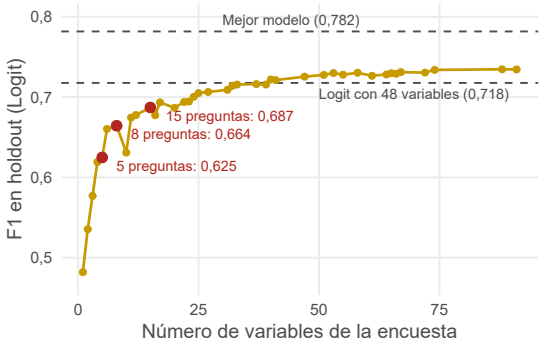


- **Subcobertura** 18,2 % (1.201 de 6.605 pobres). Brecha media de los excluidos: 0,22, frente a 0,37 del pobre promedio.
- **Filtración** 25,1 %, pero los no pobres incluidos están cerca: distancia media a la línea 0,51 (el no pobre promedio: 2,83).
- Más subcobertura en hogares de 1 y 2 personas (34 % y 28 %), Manizales (36 %) y Pereira (29 %).

Ponderando cada error por su distancia a la línea, la subcobertura baja a 11,2 % y la filtración a 1,2 %.

Holdout, umbral 0,36; brecha = 1 − ingreso/línea. Mezcla sin el modelo limpio (95 % del peso del final). Fuente: views/tablas/nivel7/etapa15_pesos_bienestar.csv, etapa15_errores_subgrupo.csv.

Una encuesta corta excluye a más pobres, y a más pobres extremos



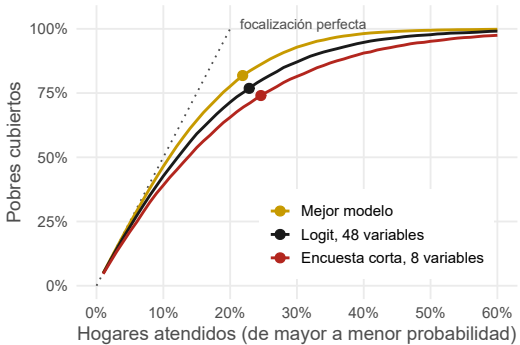
Intuición. El mejor modelo necesita el módulo laboral de cada persona: es largo y autorreportado.

- Logit con las 8 mejores preguntas (ocupados, horas, cotizantes, quién quiere más horas, arriendo pagado y recibido, dormitorios): F1 0,664 frente a 0,782.
- Subcobertura 26,0 % y filtración 39,8 %.
- El 16 % de sus excluidos está en pobreza extrema (11 % con el mejor modelo).

Acortar la encuesta ahorra costo, pero corre la exclusión hacia los más pobres.

Preguntas elegidas con NSGA-II (algoritmo genético con dos objetivos: F1 y número de preguntas). Fuente: views/tablas/nivel7/frontera_encuesta_corta.csv, etapa15_pesos_bienestar.csv.

El umbral es una decisión de política: la agencia puede comprar cobertura



El umbral que maximiza F1 supone que ambos errores cuestan igual.

- Atendiendo al 25 % de los hogares se cubre al 86,8 % de los pobres; al 30 %, al 92,9 %.
- Bajar el umbral de 0,38 a 0,21 reduce la subcobertura de 19,3 % a 9,7 %; la filtración sube de 26,5 % a 36,2 % y el F1 apenas cae (0,769 a 0,747).
- La encuesta corta necesita atender al 40 % para cubrir al 90,6 %.

Si excluir a un pobre cuesta más que incluir a un no pobre, conviene bajar el umbral.

Puntos: umbral elegido con OOF. Fuente: views/tablas/nivel7/etapa15_curva_cobertura.csv (holdout); views/tablas/escenarios_politica_n7.csv (OOF de la versión previa con auxiliares laboral y total).

Recomendación a la agencia: medir bien el trabajo de cada persona

Universidad de los Andes

1. **Con módulo laboral por persona:** modelo de ingreso por persona + LightGBM. Un LightGBM solo rinde igual que la mezcla y es más fácil de mantener.
2. **Umbral según el costo de excluir, no según F1:** con un umbral menor la subcobertura baja de 19 % a 10 %, a cambio de filtración cerca de la línea.
3. **Con presupuesto solo para encuesta corta:** usarla como filtro amplio (atender al 40 % cubre al 91 % de los pobres) y verificar con la encuesta larga a quienes quedan cerca del umbral.
4. **Vigilar los grupos con más subcobertura:** hogares de 1–2 personas, Manizales y Pereira.
5. **No esperar más de más modelos:** el techo es de información.

El valor está en medir el ingreso; el algoritmo es secundario.

Glosario (1/2): métricas y errores

Precisión	De los hogares que el programa atiende, qué parte es pobre. 1−precisión = **filtración**: no pobres que reciben el beneficio.
Recall	De los hogares pobres, qué parte atiende el programa. 1−recall = **subcobertura**: pobres excluidos.
F1	Media armónica de precisión y recall: solo es alta si ambas lo son. No premia a los no pobres bien clasificados.
Umbral	Probabilidad a partir de la cual un hogar se clasifica como pobre. Bajarlo cubre más pobres a cambio de más filtración.
IC 95 %	Rango de valores compatibles con los datos. Si el IC de una diferencia incluye cero, no podemos afirmar que haya mejora.
Efecto mínimo detectable	La mejora más pequeña que el diseño detectaría con probabilidad 0,8.

Glosario (2/2): validación y variables

Holdout	20 % del train (32.993 hogares) apartado al inicio; solo se usa para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques (folds): se entrena con 4 y se evalúa en el quinto, rotando.
Fuera de fold (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella se eligen umbral, pesos e hiperparámetros.
CV repetida	La validación cruzada repetida con 3 particiones nuevas: 15 evaluaciones para medir la variabilidad.
Auxiliar de ingreso	Modelo que predice el ingreso de cada persona con variables que el test sí trae; sumado al hogar, entra como variable.
OOF anidada	El auxiliar que alimenta a un hogar no vio ese hogar ni su fold de validación: así no se filtra la respuesta.

Apéndice: auditoría de los datos, sin fuga ni errores de construcción

Universidad de los Andes

Construcción

- 0 personas sin hogar; 0 hogares sin jefe o con varios jefes.
- Pobre $=$ (ingreso per cápita $<$ línea) en los 164.960 hogares.
- Ids de train y test sin intersección.

Fuga y cambio de distribución

- Validación adversarial (¿se distingue train de test?): AUC 0,501 con las variables observadas; 0,713 con los auxiliares, por su ajuste completo en test.
- Reponderar por esa diferencia no cambia el F1 (IC con cero).

Fuente: views/tablas/nivel7/forense_resumen.csv, forense_adversarial.csv, forense_experimentos.csv.

Apéndice: en CV repetida ninguna alternativa mejora de forma detectable

Candidato	F1 CV repetida (EE)	Δ vs. LightGBM [IC 95 %]	F1 holdout [IC 95 %]
LightGBM base	0,7752 (0,0008)		0,7806 [0,7731; 0,7885]
+ redes (mezcla sin limpio)	0,7758 (0,0008)	+0,0006 [−0,0001; +0,0013]	0,7820 [0,7743; 0,7897]
+ redes + limpio (final)	**0,7759 (0,0008)**	+0,0007 [+0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
CatBoost	0,7722 (0,0007)	−0,0030 [−0,0042; −0,0018]	0,7786 [0,7707; 0,7864]
Base con códigos corregidos	0,7754 (0,0008)	+0,0002 [−0,0002; +0,0005]	0,7797 [0,7720; 0,7875]
Rediseño desde cero	0,7478 (0,0008)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

IC pareados ingenuos (15 pares). Con la corrección de Nadeau y Bengio el IC del modelo final es [−0,0004; +0,0017]. Fuente: views/tablas/nivel7/etapa16_fase1_resumen.csv, etapa18_resumen.csv.

Apéndice: un rediseño desde cero llega a 0,750; le falta el ingreso por persona

Universidad de los Andes

- Rehicimos el pipeline sin mirar el trabajo previo: 74 variables de hogar a partir del diccionario del DANE, con los códigos de “no sabe” como faltantes.
- Una variante con el ingreso del hogar como objetivo auxiliar (anidado) no mejora.
- F1 en CV repetida 0,748 y holdout 0,750, frente a 0,775 y 0,781 de LightGBM base; correlación de sus predicciones con LightGBM: 0,94.
- Lo que separa a los dos pipelines es predecir el ingreso de cada persona, no el del hogar.

Fuente: limpio/resultados/; views/tablas/nivel7/etapa18_resumen.csv.