Best Model Overview

Reconstruir el ingreso de cada persona encuentra al 82 % de los hogares pobres

Universidad de los Andes

0,78

F1 en Kaggle: Público 0,77 → Privado 0,78 (**2.° lugar**)

0,782

F1 en el 20 % apartado (holdout)

18

submissions en Kaggle (7 algoritmos + mezclas)

El modelo

1. Estimamos el ingreso de cada persona con lo que el test sí trae: ocupación, horas, cotización.
2. Lo sumamos por hogar y lo comparamos con la línea.
3. Una mezcla liderada por LightGBM decide: pobre si $P \geq 0{,}36$.

Lo que encontramos

1. Saber cuánto gana cada persona vale más que el algoritmo.
2. Ninguna de nuestras alternativas pasa de 0,78: un tercio de los pobres está casi en la línea.
3. Los excluidos están cerca de la línea.

Kaggle: tablas pública y privada (final). LightGBM pesa 76 % de una mezcla con dos redes y un rediseño. Fuente: views/tablas/nivel7/etapa18_resumen.csv.

Ser pobre depende del ingreso, y el ingreso es justo lo que no podemos preguntar

Universidad de los Andes

Pobre: ingreso por persona bajo la línea; el test no lo trae.

- Preguntarlo es caro y poco confiable.
- “Nadie es pobre” acierta 80 %: usamos F1.

164.960

hogares

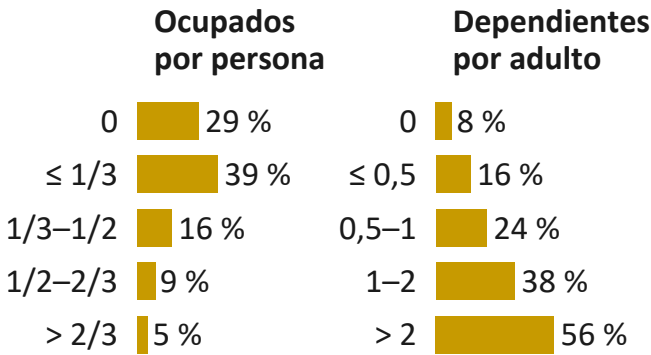
1 de 5

es pobre

Reconstruiremos el ingreso con lo que sí se ve.

Fuente: views/tablas/variables_ausentes_test_*.csv; views/tablas/desbalance_clases.csv.

Cuántos trabajan y cuántos dependen ya separan a pobres de no pobres



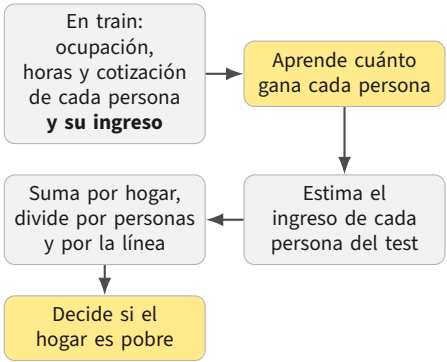
Ingreso por persona = cuántos trabajan × cuánto gana cada uno ÷ cuántos comen.

- Más dependientes: pobreza de 8 % a 56 %.
- Jefe sin estudios: 40 %; con universidad: 8 %.
- Sin ocupados (29 %) es menos pobre que un tercio ocupado (39 %): pensiones.

Ninguna variable sola basta: la mejor da un F1 de 0,47.

Tasa de pobreza en los 164.960 hogares de train; promedio: 20 %. Fuente: scripts/13_figuras_presentacion.R; views/tablas/leaderboard_interno.csv.

Si no vemos el ingreso, lo estimamos persona por persona



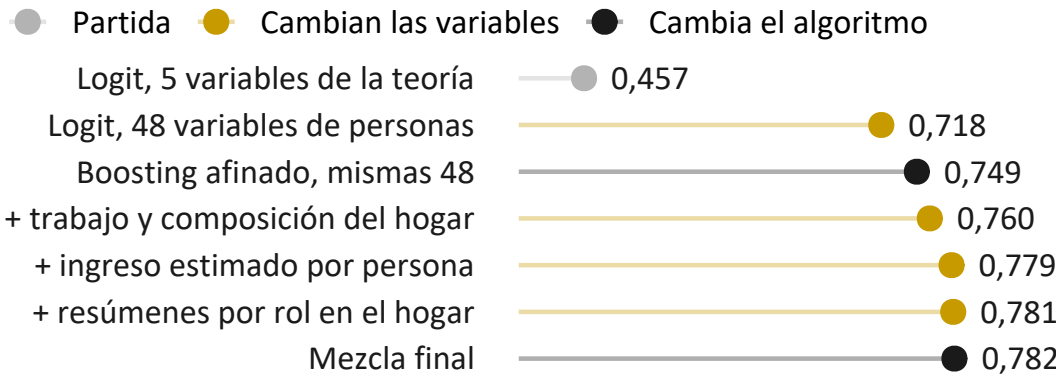
Boosting con…	F1	Cambio
sin ingreso estimado	0,760	
+ ingreso laboral	0,771	+0,011
+ ingreso total	0,776	+0,005
+ ingreso por fuente	0,779	+0,003

El modelo que estima el ingreso de un hogar nunca vio ese hogar.

El ingreso del train solo sirve para enseñar; nunca entra como dato del hogar.

F1 en los datos apartados (holdout). Boosting: LightGBM. Fuente: views/tablas/nivel7/ablacion_etapa1.csv, resumen_etapa2.csv, etapa6_ablacion.csv.

Saber cuánto gana cada persona vale más que el algoritmo



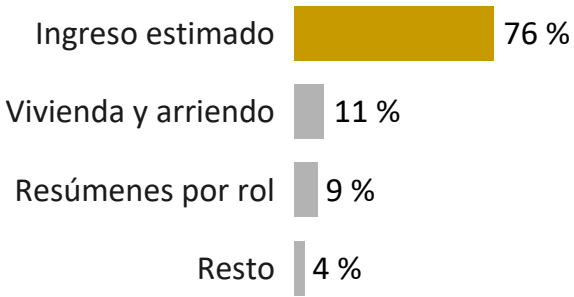
Variables: $+0{,}29$**; algoritmo:** $+0{,}03$**. Entender el hogar rinde nueve veces más.**

F1 en datos apartados, un paso a la vez. Fuente: views/tablas/leaderboard_interno.csv y views/tablas/nivel7/.

El modelo decide con el ingreso estimado y con el arriendo

Universidad de los Andes

Peso de cada grupo de variables



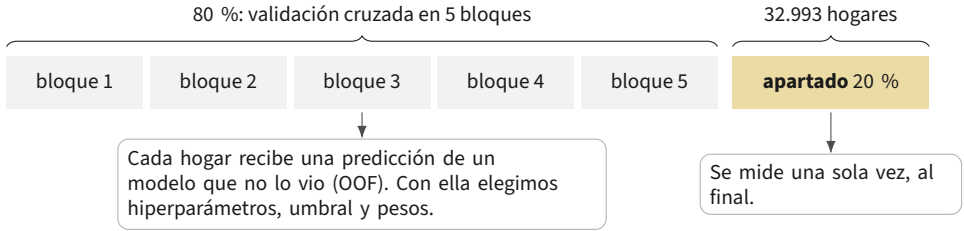
Las cinco variables con más peso	Peso
Ingreso estimado / línea (fuentes)	57 %
Ingreso estimado / línea (total)	8 %
Ingreso estimado (fuentes)	6 %
Arriendo por persona / línea	3 %
Vive en arriendo	2 %

El arriendo revela cuánto puede pagar el hogar; la casa propia pagada es un ingreso escondido.

El modelo reconstruye el ingreso y lo corrige por el costo de vivir.

Peso: cuánto reduce el error cada variable en los árboles del LightGBM, el modelo con más peso en la mezcla. Grupos: 17, 15, 1.026 y 266 variables. Fuente: views/tablas/nivel7/etapa7_a_importancia.csv, etapa15_ebm_importancia.csv.

Todo se decidió con datos que el modelo no vio



Por qué gana el boosting: suma 1.852 árboles pequeños y cada uno corrige los errores de los anteriores. Así capta cortes y combinaciones que un Logit no ve.

Repetir todo con otras particiones da el mismo F1: 0,775.

Fuente: views/tablas/resumen_particion.csv; views/tablas/nivel7/etapa16_fase1_resumen.csv (3 particiones nuevas, 15 evaluaciones).

Afinar y balancear las clases casi no mueve el F1

LightGBM: 50 combinaciones, validación cruzada

Hiperparámetro	Elegido	Qué significa
Árboles × tasa	1.852 × 0,011	aprende despacio
Hojas por árbol	31	árboles pequeños
Mínimo por hoja	171 hogares	no memoriza casos
Variables por corte	82 %	algo de azar
Hogares por árbol	70 %	algo de azar

- 75 intentos más: mismo F1 (0,776).
- Balancear las clases: 0,744 a 0,747; sin balancear, 0,746.
- Solo mueve el umbral (entre 0,34 y 0,69).

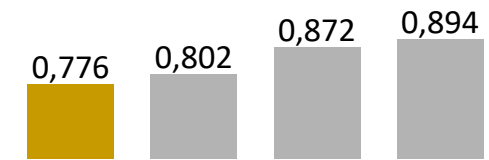
Elegir bien el umbral ya resuelve el desbalance.

Búsqueda en hipercubo latino; rangos en el apéndice del deck compare. Balanceo: pobres sintéticos (SMOTE), submuestreo y pesos de clase. Fuente: views/tablas/leaderboard_interno.csv; views/tablas/nivel7/resumen_etapa2.csv.

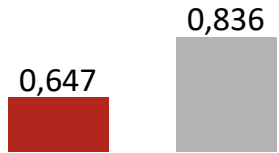
Ninguna alternativa nuestra pasa de 0,78: un tercio de los pobres está casi en la línea

Universidad de los Andes

A. Si el modelo viera el ingreso real



B. Cerca de la línea



A. Con el ingreso real, el F1 llega a 0,89.

B. Ahí está el 32 % de los pobres.

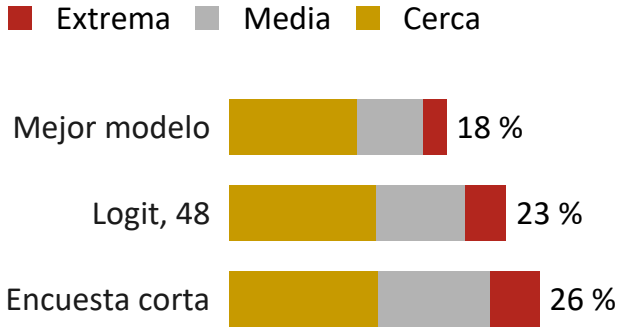
El límite es la información que falta, no el algoritmo.

Datos apartados, versión previa del modelo (0,776). Más datos y 16 alternativas: apéndice. Fuente: views/tablas/nivel7/techo_oraculo.csv, techo_bandas.csv.

Los pobres que se nos escapan están justo en la línea

Universidad de los Andes

Pobres por fuera, según su ingreso

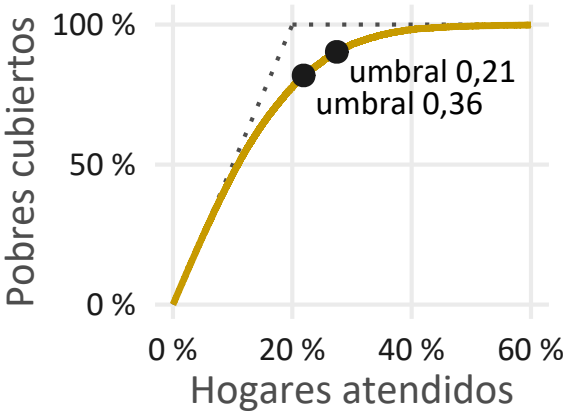


- **Subcobertura** (pobres por fuera): 18 %; seis de cada diez, cerca de la línea.
- **Filtración** (reciben sin necesitarlo): 25 %, más cerca de la línea que el no pobre típico.

Pesando por la brecha de pobreza, la subcobertura baja de 18 % a 11 %: los que se escapan son los menos pobres.

Datos apartados, umbral 0,36. Cerca: ingreso $\geq$ 0,8 veces la línea; extrema: $<$ 0,5. Logit, 48: con 48 variables. Mezcla sin el rediseño (95 % del peso final).
Fuente: views/tablas/nivel7/etapa15_pesos_bienestar.csv.

El umbral es una decisión de política, no estadística



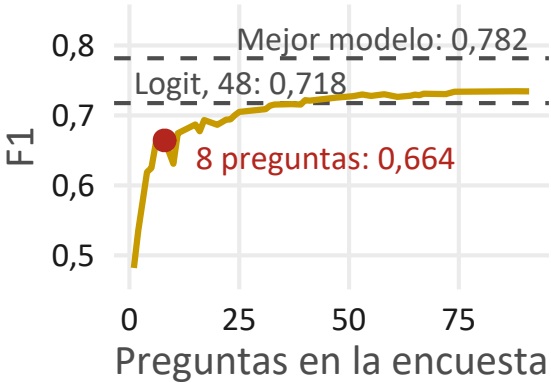
El F1 supone que ambos errores cuestan igual.

- Umbral de 0,36 a 0,21: subcobertura de 18 % a 10 %.
- Filtración de 25 % a 34 %; F1 de 0,78 a 0,76.

Si dejar a un pobre por fuera cuesta más, conviene bajar el umbral.

Modelo final (n18), datos apartados. Umbrales elegidos en OOF. Punteada: focalización perfecta. Fuente: views/tablas/nivel7/umbral_n18_*.csv.

Una encuesta corta ahorra plata, pero deja por fuera a más pobres extremos



Nuestro modelo necesita el módulo de trabajo de cada persona: largo y caro.

- 8 preguntas: F1 de 0,66.
- Pobres por fuera: 26 % (mejor modelo: 18 %).
- De ellos, en pobreza extrema: 16 % (11 %).

Lo que se ahorra en la encuesta lo pagan los más pobres.

Logit, datos apartados; preguntas elegidas con un algoritmo genético. Kaggle: 0,66 con XGBoost y 10 preguntas. Fuente: views/tablas/nivel7/frontera_encuesta_corta.csv, etapa15_pesos_bienestar.csv.

Recomendación: preguntar bien por el trabajo de cada persona

Universidad de los Andes

1. **Medir el trabajo de cada persona**; basta un LightGBM.
2. **Umbral según el costo de excluir.**
3. **Poco presupuesto:** encuesta corta y verificar cerca del umbral.
4. **Vigilar** hogares pequeños, Manizales y Pereira.

Medir bien el ingreso vale más que el algoritmo.

Atendiendo al 30 % de los hogares se cubre al 92,9 % de los pobres con el modelo, al 87,1 % con el Logit y al 81,5 % con la encuesta corta (datos apartados).
Fuente: views/tablas/nivel7/etapa15_curva_cobertura.csv, etapa15_errores_subgrupo.csv.

Glosario (1/2): cómo medimos los errores

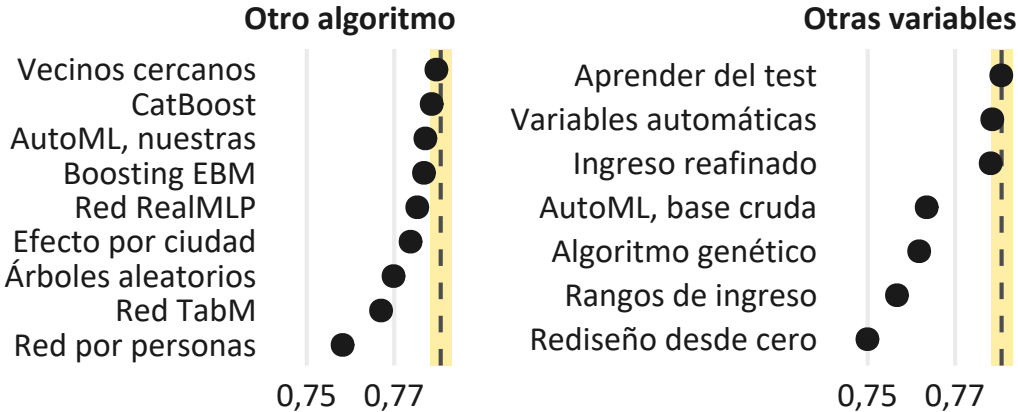
Precisión	De los hogares que el programa atiende, qué parte es pobre.
Filtración	1−precisión: hogares no pobres que reciben el subsidio sin necesitarlo.
Recall	De los hogares pobres, qué parte atiende el programa.
Subcobertura	1−recall: hogares pobres que se quedan por fuera.
F1	Promedio (armónico) de precisión y recall: solo es alto si ambos lo son.
Umbral	Probabilidad desde la que un hogar se declara pobre. Bajarlo cubre más pobres a cambio de más filtración.

Glosario (2/2): cómo validamos

Universidad de los Andes

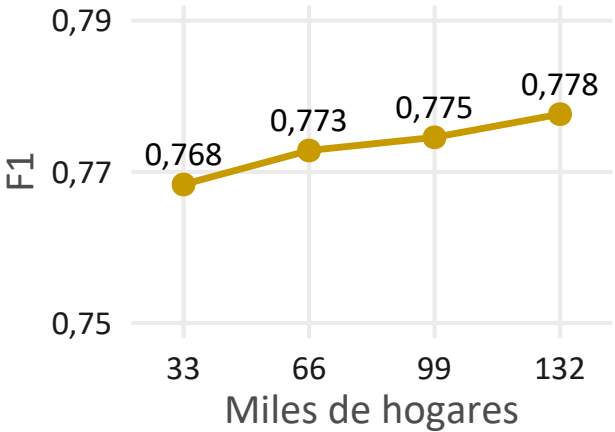
Datos apartados (holdout)	20 % del train (32.993 hogares) separado al inicio; solo sirve para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques: se entrena con 4 y se evalúa en el quinto, rotando.
Predicción sobre datos no vistos (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella elegimos umbral, pesos e hiperparámetros.
Modelo de ingreso por persona	Estima cuánto gana cada persona con lo que el test sí trae; sumado al hogar, entra como variable. El que alimenta a un hogar nunca vio ese hogar.
Diferencia más pequeña que podemos medir	Con 32.993 hogares, mejoras menores a $\approx 0{,}0025$ de F1 no se distinguen del ruido.

Apéndice: 16 alternativas más chocan con el mismo techo



F1 en datos apartados. Punteada: LightGBM base (0,781); banda: diferencia mínima medible (±0,0025). Fuente: views/tablas/nivel7/ (etapa7_b a etapa18).

Apéndice: cuadruplicar los datos sube el F1 apenas una centésima



Entrenamos con 25, 50, 75 y 100 % del 80 % de train.

- De 33 mil a 132 mil hogares: F1 de 0,768 a 0,778.
- La curva se aplana: más datos no rompen el techo.

F1 en los datos apartados (holdout) con una versión previa del modelo. Fuente: views/tablas/nivel7/techo_curva_aprendizaje.csv.

Apéndice: no hay fuga de información y train se parece al test

Universidad de los Andes

Construcción

- 0 personas sin hogar; 0 hogares sin jefe o con varios jefes.
- Pobre $=$ (ingreso por persona $<$ línea) en los 164.960 hogares.
- Ningún hogar está a la vez en train y en test.

Prueba de que train y test se parecen

- Un clasificador no logra distinguirlos (AUC 0,501) con las variables observadas.
- Con el ingreso estimado sube a 0,713, porque en test se calcula con el modelo completo. Corregirlo no cambia el F1.

Validación adversarial. Fuente: views/tablas/nivel7/forense_resumen.csv, forense_adversarial.csv, forense_experimentos.csv.

Apéndice: en validación repetida, ninguna alternativa mejora de forma medible

Universidad de los Andes

Candidato	F1 validación repetida (EE)	Diferencia vs. LightGBM [IC 95 %]	F1 apartado [IC 95 %]
LightGBM base	0,7752 (0,0008)		0,7806 [0,7731; 0,7885]
+ redes (mezcla sin rediseño)	0,7758 (0,0008)	+0,0006 [−0,0001; +0,0013]	0,7820 [0,7743; 0,7897]
+ redes + rediseño (final)	**0,7759 (0,0008)**	+0,0007 [+0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
CatBoost	0,7722 (0,0007)	−0,0030 [−0,0042; −0,0018]	0,7786 [0,7707; 0,7864]
Base con códigos corregidos	0,7754 (0,0008)	+0,0002 [−0,0002; +0,0005]	0,7797 [0,7720; 0,7875]
Rediseño desde cero	0,7478 (0,0008)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

15 evaluaciones (3 particiones nuevas $\times$ 5 bloques), IC pareados ingenuos. Con la corrección de Nadeau y Bengio por dependencia entre bloques, el IC del modelo final es $[-0{,}0004; +0{,}0017]$. Fuente: views/tablas/nivel7/etapa16_fase1_resumen.csv, etapa18_resumen.csv.

Apéndice: un rediseño desde cero llega a 0,750; le falta el ingreso por persona

Universidad de los Andes

- Rehicimos todo sin mirar el trabajo previo: 74 variables de hogar desde el diccionario del DANE, con “no sabe” como faltante.
- Estimar el ingreso del hogar (no el de cada persona) no ayuda.
- F1 de 0,748 en validación repetida y 0,750 en datos apartados, frente a 0,775 y 0,781 del LightGBM base.
- Lo que separa a los dos es estimar el ingreso de cada persona.

Fuente: limpio/resultados/; views/tablas/nivel7/etapa18_resumen.csv.