Best Model Overview

Reconstruir el ingreso de cada persona encuentra al 82 % de los hogares pobres

Universidad de los Andes

0,78

F1 final en Kaggle: **2.° lugar**

0,782

F1 en el 20 % apartado (holdout)

35

submissions, 7 algoritmos

El modelo

1. Estimamos el ingreso de cada persona con lo que el test sí trae: ocupación, horas, cotización.
2. Lo sumamos por hogar y lo comparamos con la línea.
3. Un boosting de árboles (LightGBM) decide: pobre si $P \geq 0{,}36$.

Lo que encontramos

1. Saber cuánto gana cada persona vale más que el algoritmo.
2. Nadie pasa de 0,78: un tercio de los pobres está casi en la línea.
3. Los excluidos están cerca de la línea.

Kaggle: tabla final (privada). LightGBM pesa 76 % de una mezcla con dos redes y un rediseño. Fuente: views/tablas/nivel7/etapa18_resumen.csv.

Ser pobre depende del ingreso, y el ingreso es justo lo que no podemos preguntar

Universidad de los Andes

Pobre: ingreso por persona bajo la línea de su ciudad. El test no trae ingresos.

- Preguntarlo es caro, la gente lo esconde y cambia mes a mes.
- “Nadie es pobre” acierta 80 %, pero no encuentra a ningún pobre: usamos F1.

164.960

hogares para entrenar

1 de 5

es pobre

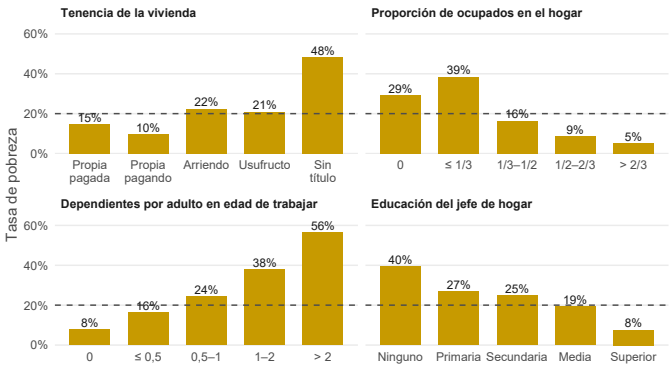
Hay que reconstruir el ingreso con lo que sí se ve.

66.168 hogares para predecir. 79 variables solo existen en train, entre ellas todos los ingresos. Fuente: views/tablas/variables_ausentes_test_*.csv; views/tablas/desbalance_clases.csv.

Cuántos trabajan y cuántos dependen ya separan a pobres de no pobres

Universidad de los Andes

Tasa de pobreza en train (164.960 hogares). Línea punteada: promedio (20,0%)



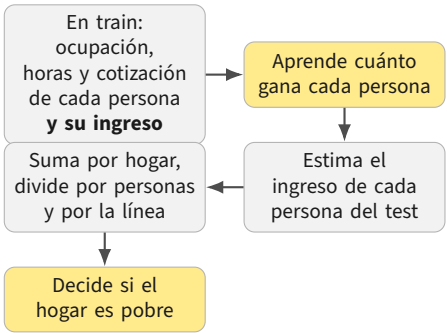
Ingreso por persona = cuántos trabajan × cuánto gana cada uno ÷ cuántos comen.

- Más dependientes: pobreza de 8 % a 56 %.
- Jefe sin estudios: 40 %; con universidad: 8 %.
- Sin ocupados (29 %) es menos pobre que un tercio ocupado (39 %): pensiones.

Ninguna variable sola basta: la mejor da un F1 de 0,47.

Tasa de pobreza en los 164.960 hogares de train. Fuente: scripts/13_figuras_presentacion.R; views/tablas/leaderboard_interno.csv.

Si no vemos el ingreso, lo estimamos persona por persona



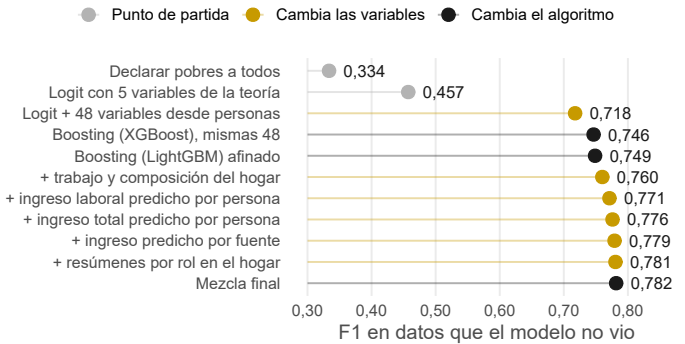
Boosting con…	F1	Cambio
sin ingreso estimado	0,760	
+ ingreso laboral	0,771	+0,011
+ ingreso total	0,776	+0,005
+ ingreso por fuente	0,779	+0,003

El modelo que estima el ingreso de un hogar nunca vio ese hogar.

El ingreso del train solo sirve para enseñar; nunca entra como dato del hogar.

F1 en los datos apartados (holdout). Boosting: LightGBM. Fuente: views/tablas/nivel7/ablacion_etapa1.csv, resumen_etapa2.csv, etapa6_ablacion.csv.

Saber cuánto gana cada persona vale más que el algoritmo



Suma de los saltos

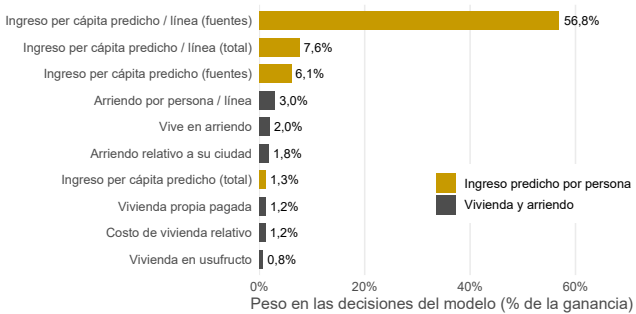
- **Mejores variables**: $+0{,}29$.
- **Mejor algoritmo**: $+0{,}03$.

Salto mayor: el mismo Logit con variables desde las personas.

Rinde nueve veces más entender el hogar que cambiar de algoritmo.

F1 en los datos apartados (holdout), un paso a la vez. Fuente: views/tablas/leaderboard_interno.csv y nivel7/ (ablacion_etapa1, resumen_etapa2, etapa6_ablacion, etapa7_a, etapa18_resumen).

El modelo decide con el ingreso estimado y con el arriendo



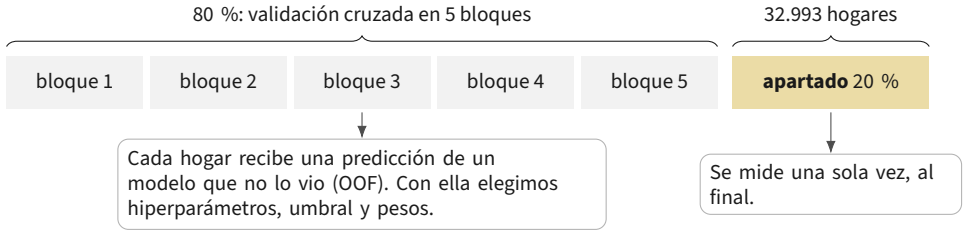
Grupo	Variables	Peso
Ingreso estimado	17	76 %
Vivienda y arriendo	15	11 %
Resúmenes por rol	1.026	9 %
Resto	266	4 %

El arriendo revela cuánto puede pagar el hogar; la casa propia pagada es un ingreso escondido.

El modelo reconstruye el ingreso y lo corrige por el costo de vivir.

Peso: cuánto reduce el error cada variable en los árboles del LightGBM (76 % de la mezcla). Fuente: views/tablas/nivel7/etapa7_a_importancia.csv, etapa15_ebm_importancia.csv.

Todo se decidió con datos que el modelo no vio



Por qué gana el boosting: suma 1.852 árboles pequeños y cada uno corrige los errores de los anteriores. Así capta cortes y combinaciones que un Logit no ve.

Repetir todo con otras particiones da el mismo F1: 0,775.

Fuente: views/tablas/resumen_particion.csv; views/tablas/nivel7/etapa16_fase1_resumen.csv (3 particiones nuevas, 15 evaluaciones).

Afinar y balancear las clases casi no mueve el F1

LightGBM: 50 combinaciones, validación cruzada

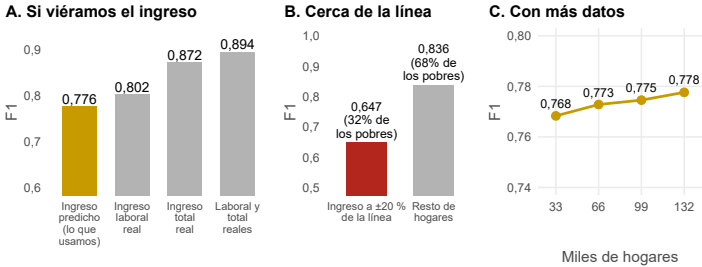
Hiperparámetro	Elegido	Qué significa
Árboles × tasa	1.852 × 0,011	aprende despacio
Hojas por árbol	31	árboles pequeños
Mínimo por hoja	171 hogares	no memoriza casos
Variables por corte	82 %	algo de azar
Hogares por árbol	70 %	algo de azar

- 75 intentos más: mismo F1 (0,776).
- Balancear las clases: 0,744 a 0,747; sin balancear, 0,746.
- Solo cambia el umbral (0,36 → 0,66).

Elegir bien el umbral ya resuelve el desbalance.

Búsqueda en hipercubo latino; rangos en el apéndice del deck compare. Balanceo: pobres sintéticos (SMOTE), submuestreo y pesos de clase. Fuente: views/tablas/leaderboard_interno.csv; views/tablas/nivel7/resumen_etapa2.csv.

Ningún modelo pasa de 0,78: un tercio de los pobres está casi en la línea



A. Con el ingreso real: 0,89.

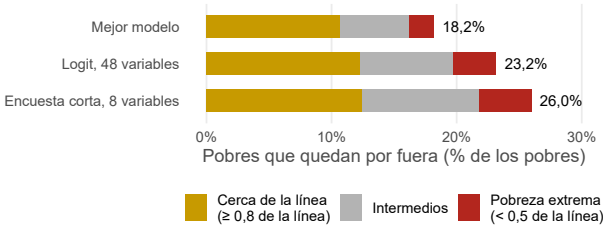
B. 32 % de los pobres, a $\pm$ 20 % de la línea: 0,65.

C. Cuatro veces más datos: $+$0,01.

El límite es la información que falta, no el algoritmo.

F1 en los datos apartados con una versión previa del modelo (0,776). 16 alternativas más quedan entre 0,750 y 0,782 (apéndice). Fuente: views/tablas/nivel7/techo_oraculo.csv, techo_bandas.csv, techo_curva_aprendizaje.csv.

Los pobres que se nos escapan están justo en la línea

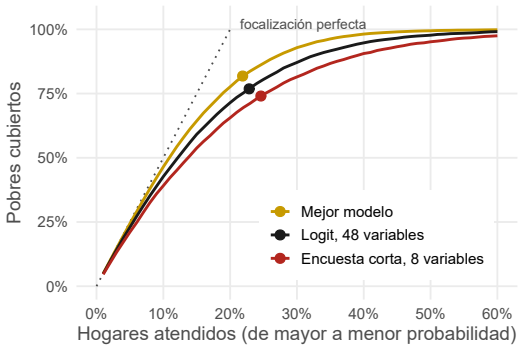


- **Subcobertura** (pobres por fuera): 18 %; seis de cada diez, cerca de la línea.
- **Filtración** (reciben sin necesitarlo): 25 %, más cerca de la línea que el no pobre típico.

Pesando cada error por su distancia a la línea: subcobertura 11 %, filtración 1 %.

Datos apartados (holdout), umbral 0,36. Cerca de la línea: ingreso $\geq$ 0,8 veces la línea. Pobreza extrema: $<$ 0,5. Mezcla sin el rediseño (95 % del peso final).
Fuente: views/tablas/nivel7/etapa15_pesos_bienestar.csv, etapa15_errores_subgrupo.csv.

El umbral es una decisión de política, no estadística



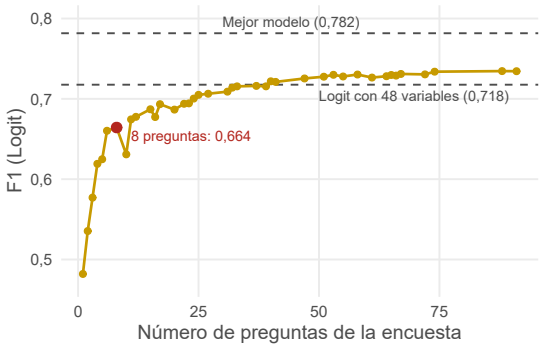
El F1 supone que ambos errores cuestan igual.

- Umbral de 0,38 a 0,21: subcobertura de 19 % a 10 %.
- Filtración de 27 % a 36 %; F1 de 0,77 a 0,75.

Si dejar a un pobre por fuera cuesta más, conviene bajar el umbral.

Curva y puntos en los datos apartados (holdout); umbrales calculados con una versión previa del modelo. Fuente: views/tablas/nivel7/etapa15_curva_cobertura.csv; views/tablas/escenarios_politica_n7.csv.

Una encuesta corta ahorra plata, pero deja por fuera a más pobres extremos



Nuestro modelo necesita el módulo de trabajo de cada persona: largo y caro.

- 8 preguntas: F1 de 0,66.
- Pobres por fuera: 26 % (mejor modelo: 18 %).
- De ellos, en pobreza extrema: 16 % (11 %).

Lo que se ahorra en la encuesta lo pagan los más pobres.

Logit, datos apartados (holdout). Las 8 preguntas: ocupados, horas, cotizantes, quién quiere trabajar más, arriendo pagado y recibido, dormitorios; elegidas con un algoritmo genético. Fuente: views/tablas/nivel7/frontera_encuesta_corta.csv, etapa15_pesos_bienestar.csv.

Recomendación: preguntar bien por el trabajo de cada persona

Universidad de los Andes

1. **Medir el trabajo de cada persona**; un LightGBM solo basta.
2. **Umbral según el costo de excluir**, no según el F1.
3. **Poco presupuesto:** encuesta corta como filtro y verificar cerca del umbral.
4. **Vigilar** hogares de 1–2 personas, Manizales y Pereira.

El valor está en medir bien el ingreso, no en el algoritmo.

Encuesta corta: atendiendo al 40 % de los hogares cubre al 91 % de los pobres. Fuente: views/tablas/nivel7/etapa15_curva_cobertura.csv, etapa15_errores_subgrupo.csv.

Glosario (1/2): cómo medimos los errores

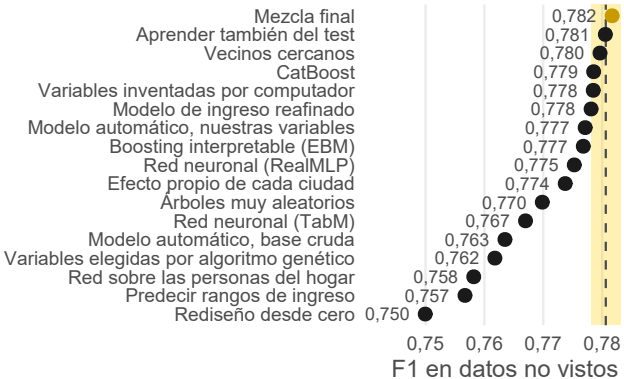
Precisión	De los hogares que el programa atiende, qué parte es pobre.
Filtración	1−precisión: hogares no pobres que reciben el subsidio sin necesitarlo.
Recall	De los hogares pobres, qué parte atiende el programa.
Subcobertura	1−recall: hogares pobres que se quedan por fuera.
F1	Promedio (armónico) de precisión y recall: solo es alto si ambos lo son.
Umbral	Probabilidad desde la que un hogar se declara pobre. Bajarlo cubre más pobres a cambio de más filtración.

Glosario (2/2): cómo validamos

Universidad de los Andes

Datos apartados (holdout)	20 % del train (32.993 hogares) separado al inicio; solo sirve para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques: se entrena con 4 y se evalúa en el quinto, rotando.
Predicción sobre datos no vistos (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella elegimos umbral, pesos e hiperparámetros.
Modelo de ingreso por persona	Estima cuánto gana cada persona con lo que el test sí trae; sumado al hogar, entra como variable. El que alimenta a un hogar nunca vio ese hogar.
Diferencia más pequeña que podemos medir	Con 32.993 hogares, mejoras menores a $\approx 0{,}0025$ de F1 no se distinguen del ruido.

Apéndice: dieciséis alternativas más chocan con el mismo techo



Banda amarilla: la diferencia más pequeña que podemos medir ($\pm$0,0025) alrededor del LightGBM base (línea punteada).

- Ninguna alternativa supera al LightGBM por fuera de la banda.
- La mezcla final gana $+$0,0007 en validación repetida.

F1 en los datos apartados (holdout). Fuente: views/tablas/nivel7/ (etapa7_b, etapa8 a etapa18); banda de etapa16_fase1_resumen.csv.

Apéndice: no hay fuga de información y train se parece al test

Universidad de los Andes

Construcción

- 0 personas sin hogar; 0 hogares sin jefe o con varios jefes.
- Pobre $=$ (ingreso por persona $<$ línea) en los 164.960 hogares.
- Ningún hogar está a la vez en train y en test.

Prueba de que train y test se parecen

- Un clasificador no logra distinguirlos (AUC 0,501) con las variables observadas.
- Con el ingreso estimado sube a 0,713, porque en test se calcula con el modelo completo. Corregirlo no cambia el F1.

Validación adversarial. Fuente: views/tablas/nivel7/forense_resumen.csv, forense_adversarial.csv, forense_experimentos.csv.

Apéndice: en validación repetida, ninguna alternativa mejora de forma medible

Candidato	F1 validación repetida (EE)	Diferencia vs. LightGBM [IC 95 %]	F1 apartado [IC 95 %]
LightGBM base	0,7752 (0,0008)		0,7806 [0,7731; 0,7885]
+ redes (mezcla sin rediseño)	0,7758 (0,0008)	+0,0006 [−0,0001; +0,0013]	0,7820 [0,7743; 0,7897]
+ redes + rediseño (final)	**0,7759 (0,0008)**	+0,0007 [+0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
CatBoost	0,7722 (0,0007)	−0,0030 [−0,0042; −0,0018]	0,7786 [0,7707; 0,7864]
Base con códigos corregidos	0,7754 (0,0008)	+0,0002 [−0,0002; +0,0005]	0,7797 [0,7720; 0,7875]
Rediseño desde cero	0,7478 (0,0008)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

15 evaluaciones (3 particiones nuevas $\times$ 5 bloques), IC pareados ingenuos. Con la corrección de Nadeau y Bengio por dependencia entre bloques, el IC del modelo final es $[-0{,}0004; +0{,}0017]$. Fuente: views/tablas/nivel7/etapa16_fase1_resumen.csv, etapa18_resumen.csv.

Apéndice: un rediseño desde cero llega a 0,750; le falta el ingreso por persona

Universidad de los Andes

- Rehicimos todo sin mirar el trabajo previo: 74 variables de hogar desde el diccionario del DANE, con “no sabe” como faltante.
- Estimar el ingreso del hogar (no el de cada persona) no ayuda.
- F1 de 0,748 en validación repetida y 0,750 en datos apartados, frente a 0,775 y 0,781 del LightGBM base.
- Lo que separa a los dos es estimar el ingreso de cada persona.

Fuente: limpio/resultados/; views/tablas/nivel7/etapa18_resumen.csv.