Best Model Overview

Reconstruir el ingreso de cada persona encuentra al 82 % de los hogares pobres

Universidad de los Andes

0,78

F1 en Kaggle: Público 0,77 → Privado 0,78 (**2.° lugar**)

0,782

F1 en el 20 % apartado (holdout)

18

submissions en Kaggle (7 algoritmos + mezclas)

El modelo

1. Estimamos el ingreso de cada persona con lo que el test sí trae: ocupación, horas, cotización.
2. Lo sumamos por hogar y lo comparamos con la línea.
3. Una mezcla liderada por LightGBM decide: pobre si $P \geq 0{,}36$.

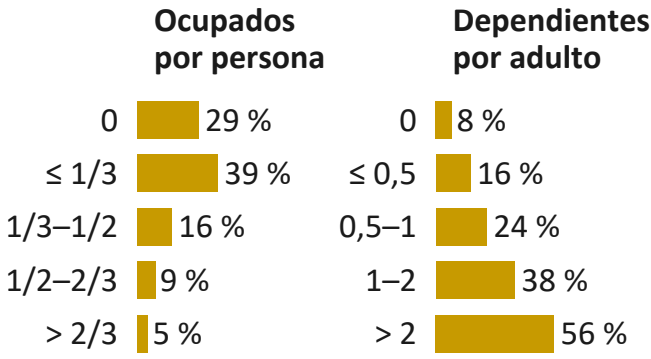
Lo que encontramos

1. Saber cuánto gana cada persona vale más que el algoritmo.
2. Ninguna de nuestras alternativas pasa de 0,78: un tercio de los pobres está casi en la línea.
3. Los excluidos están cerca de la línea.

Kaggle: tablas pública y privada (final). LightGBM pesa 76 % de una mezcla con dos redes y un rediseño. Fuente: views/tablas/nivel7/etapa18_resumen.csv.

La pobreza cambia por saltos y combinaciones: terreno de los árboles

Universidad de los Andes



Un modelo lineal suma efectos; un árbol corta y combina.

- **Saltos:** con más ocupados, la pobreza sube (29 % a 39 %) y luego cae (5 %).
- **Combinaciones:** el arriendo pesa distinto si la casa es propia.
- 1 de cada 5 hogares es pobre.

Esperamos que los árboles ganen.

Tasa de pobreza en los 164.960 hogares de train; promedio: 20 %. Fuente: scripts/13_figuras_presentacion.R; views/tablas/nivel7/etapa15_ebm_importancia.csv.

Cancha nivelada: mismas 48 variables, misma preparación y misma validación

Universidad de los Andes

Algoritmo	Qué se buscó (validación cruzada, 5 bloques)	Elegido	Intentos
LPM y Logit	sin hiperparámetros		1
Elastic Net	grilla: penalización $10^{[-5,\,0]}$ × mezcla L1/L2 [0, 1]	0,0002; 0,2	120
CART	grilla: complejidad $10^{[-5,\,-1]}$ × profundidad [3, 15]	6×10^{-5}; 10	36
Naive Bayes	grilla: suavizado [0,5; 1,5] × Laplace [0, 3]	0,5; 0	16
Random Forest	aleatoria: variables por corte [3, 25] × hoja [5, 60]	23; 24	15
Boosting (XGBoost)	aleatoria: árboles [200, 1000] × profundidad [3, 8] × tasa $10^{[-3,\,-1]}$	781; 6; 0,020	20
Boosting (LightGBM)	aleatoria: 7 hiperparámetros (apéndice)		50

Todos eligen el umbral con predicciones sobre datos que el modelo no vio (OOF) y se miden en el mismo 20 % apartado.

Las diferencias de F1 vienen del algoritmo, no de los datos que recibe.

Búsqueda aleatoria: hipercubo latino. La preparación (imputación, dummies y escalado) se ajusta dentro de cada bloque. Fuente: views/tablas/leaderboard_interno.csv.

Con las mismas variables, el boosting gana y Naive Bayes queda último

Universidad de los Andes

	F1				
Algoritmo	Validación	Apartado	Kaggle	Filtración	Subcobertura
Boosting (LightGBM)	**0,744**	**0,749**	**0,75**	29 %	20 %
Boosting (XGBoost)	0,740	0,746	0,74	30 %	21 %
Random Forest	0,726	0,734	0,73	32 %	20 %
Elastic Net	0,717	0,718	0,72	33 %	22 %
Logit	0,717	0,718	0,72	33 %	23 %
CART	0,697	0,701	—	34 %	25 %
LPM	0,690	0,691	—	35 %	26 %
Naive Bayes	0,643	0,640	—	44 %	25 %

Filtración: reciben sin necesitarlo. **Subcobertura:** pobres por fuera.

- Mismo orden en validación y en datos apartados.
- Los mejores ganan en filtración.

Los más cercanos al boosting: Random Forest y Elastic Net.

48 variables, 32.993 hogares apartados (holdout). Kaggle: F1 privado de la submission de cancha nivelada (XGBoost y Elastic Net: con 8 variables complementarias más); —: no subido. Fuente: views/tablas/comparacion_algoritmos.csv; stores/submissions/bitacora_kaggle.csv.

Random Forest encuentra a los mismos pobres, pero incluye más no pobres

48 variables	Random Forest	XGBoost
Pobres encontrados (recall)	80 %	79 %
Precisión	68 %	70 %
No pobres incluidos	2.483	2.206
Pobres excluidos	1.332	1.358
F1	0,734	0,746

Bosque: árboles profundos en paralelo, promediados. **XGBoost:** árboles pequeños que corrigen los errores anteriores.

- Bosque: 277 no pobres más.

XGBoost gana por filtrar menos, no por cubrir más.

48 variables, datos apartados (holdout). Fuente: views/tablas/leaderboard_interno.csv.

Elastic Net empata con el Logit: le faltan cortes, no penalización

Universidad de los Andes

Por qué empata con el Logit

- 132 mil hogares y 48 variables: no hay sobreajuste que evitar.
- La validación cruzada elige casi no penalizar (0,0002).

Datos apartados	Elastic Net	Boosting
F1	0,718	0,749
Subcobertura	22,4 %	20,4 %
Pobres excluidos	1.478	1.347
Se puede leer	sí	no directamente

Ser lineal cuesta unos 130 pobres excluidos, pero se audita.

Boosting: LightGBM. LPM (probabilidad lineal): 0,691. Fuente: views/tablas/leaderboard_interno.csv (n4_elastic_net, n3_logit, n3_lpm, n6_lightgbm).

Balancear las clases no mejora a nadie: solo mueve el umbral

XGBoost, 48 variables	F1	Umbral elegido
Sin balancear	0,746	0,36
Pobres sintéticos (SMOTE)	0,745	0,34
Más peso a los pobres	0,744	0,66
Menos no pobres	0,747	0,69

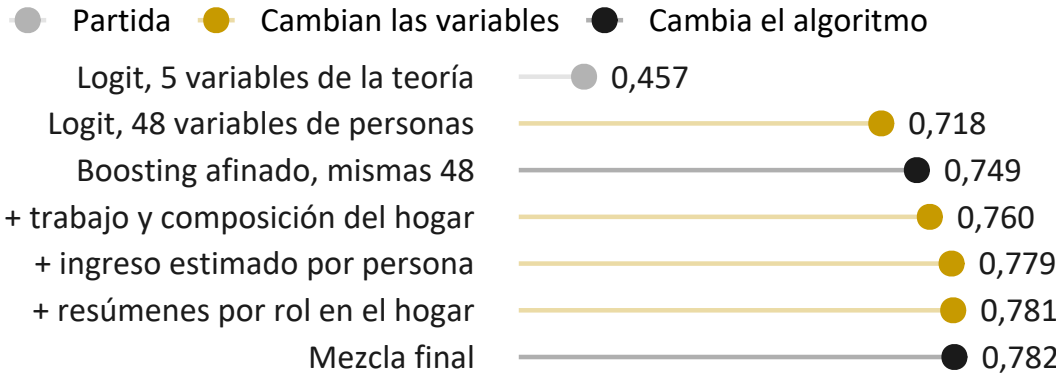
Balancear infla la probabilidad de ser pobre. Al elegir el umbral que maximiza el F1, el umbral sube y deshace el cambio.

Elegir bien el umbral ya resuelve el desbalance.

Datos apartados (holdout). Diferencias de 0,002 o menos, por debajo de lo que podemos medir. Fuente: views/tablas/leaderboard_interno.csv (n4_xgboost y n5_*).

Cambiar las variables vale nueve veces más que cambiar el algoritmo

Universidad de los Andes



Variables: $+0{,}29$; algoritmo: $+0{,}03$. Saber cuánto gana cada persona vale más.

F1 en datos apartados, un paso a la vez. Fuente: views/tablas/leaderboard_interno.csv y views/tablas/nivel7/.

Con buenas variables, todos los algoritmos llegan al mismo techo

Universidad de los Andes

Con ingreso estimado	F1	Parecido
Boosting (LightGBM)	**0,781**	1
Boosting (CatBoost)	0,779	0,994
Modelo automático (AutoML)	0,777	0,990
Red neuronal (RealMLP)	0,775	0,984
Red neuronal (TabM)	0,767	0,977

Si todos predicen casi lo mismo, se agotó la información.

- Modelo automático, base cruda: 0,763.
- Mezclar los mejores: 0,782.

El techo es de información: un tercio de los pobres está casi en la línea.

1.324 variables. F1 en datos apartados (holdout). Parecido: correlación con las predicciones de LightGBM sobre datos no vistos. Fuente: views/tablas/nivel7/etapa7_b.csv, etapa10_candidatos.csv, etapa12_resumen.csv, etapa18_resumen.csv, techo_bandas.csv.

Más complejidad protege mejor a los más pobres, pero cuesta más medirla

	Encuesta corta (Logit)	Logit completo	Mejor modelo
Preguntas o variables	8	48	1.324 (incluye ingreso estimado)
F1 en datos apartados	0,664	0,718	0,782
Subcobertura (pobres por fuera)	26 %	23 %	18 %
Filtración (reciben sin necesitarlo)	40 %	33 %	25 %
De los excluidos, en pobreza extrema	16 %	15 %	11 %
Cómo se explica	coeficientes	coeficientes	importancia de variables
Costo de recolección	bajo	medio	alto (módulo de trabajo)

La complejidad se justifica por a quién deja de excluir, no por el F1.

Pobreza extrema: ingreso menor a la mitad de la línea. Umbral elegido con datos no vistos. Fuente: views/tablas/nivel7/etapa15_pesos_bienestar.csv (mejor modelo: mezcla sin el rediseño).

¿El modelo con más puntaje en Kaggle? No necesariamente

Universidad de los Andes

1. **Elegir por el costo de cada error.**
2. **LightGBM solo**: rinde igual que la mezcla.
3. **Transparencia**: EBM, boosting interpretable (0,777) o Logit (0,718).
4. **Encuesta corta**: umbral más bajo y verificación en campo.

Decide qué se puede medir y cuánto cuesta excluir.

Fuente: views/tablas/nivel7/etapa15_resumen.csv; views/tablas/leaderboard_interno.csv; views/tablas/nivel7/etapa18_resumen.csv.

Glosario (1/2): cómo medimos los errores

Precisión	De los hogares que el programa atiende, qué parte es pobre.
Filtración	1−precisión: hogares no pobres que reciben el subsidio sin necesitarlo.
Recall	De los hogares pobres, qué parte atiende el programa.
Subcobertura	1−recall: hogares pobres que se quedan por fuera.
F1	Promedio (armónico) de precisión y recall: solo es alto si ambos lo son.
Umbral	Probabilidad desde la que un hogar se declara pobre. Bajarlo cubre más pobres a cambio de más filtración.

Glosario (2/2): cómo validamos

Datos apartados (holdout)	20 % del train (32.993 hogares) separado al inicio; solo sirve para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques: se entrena con 4 y se evalúa en el quinto, rotando.
Predicción sobre datos no vistos (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella elegimos umbral, pesos e hiperparámetros.
Modelo de ingreso por persona	Estima cuánto gana cada persona con lo que el test sí trae; sumado al hogar, entra como variable. El que alimenta a un hogar nunca vio ese hogar.
Diferencia más pequeña que podemos medir	Con 32.993 hogares, mejoras menores a $\approx 0{,}0025$ de F1 no se distinguen del ruido.

Apéndice: hiperparámetros del LightGBM ganador

Hiperparámetro	Rango explorado	Elegido	Qué significa
Número de árboles	[200, 2000]	1.852	muchos árboles
Tasa de aprendizaje	$10^{[-3,\ -0{,}7]}$	0,011	pasos pequeños
Profundidad máxima	[3, 12]	12 (31 hojas)	árboles pequeños
Mínimo de hogares por hoja	[10, 200]	171	no memoriza casos
Variables por corte	[0,2; 1]	0,82	algo de azar
Hogares por árbol	[0,5; 1]	0,70	algo de azar
Ganancia mínima para cortar	$10^{[-10,\ 1]}$	7×10^{-10}	sin restricción

Búsqueda aleatoria (hipercubo latino) de 50 combinaciones, validación cruzada de 5 bloques sobre las 48 variables. Fuente: views/tablas/leaderboard_interno.csv (n6_lightgbm).

Apéndice: en validación repetida, ninguna alternativa mejora de forma medible

Universidad de los Andes

Candidato	F1 validación repetida (EE)	Diferencia vs. LightGBM [IC 95 %]	F1 apartado [IC 95 %]
LightGBM base	0,7752 (0,0008)		0,7806 [0,7731; 0,7885]
+ redes (mezcla sin rediseño)	0,7758 (0,0008)	+0,0006 [−0,0001; +0,0013]	0,7820 [0,7743; 0,7897]
+ redes + rediseño (final)	**0,7759 (0,0008)**	+0,0007 [+0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
CatBoost	0,7722 (0,0007)	−0,0030 [−0,0042; −0,0018]	0,7786 [0,7707; 0,7864]
Rediseño desde cero	0,7478 (0,0008)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

15 evaluaciones (3 particiones nuevas × 5 bloques), IC pareados ingenuos. Con la corrección de Nadeau y Bengio el IC del modelo final es [−0,0004; +0,0017].
Fuente: views/tablas/nivel7/etapa16_fase1_resumen.csv, etapa18_resumen.csv.