Best Model Overview

Ingreso predicho por persona + LightGBM | Equipo 06, MECA 4107

Universidad de los Andes

[pendiente]

F1 público en Kaggle

0,782

F1 en holdout, IC 95 % [0,774; 0,789]

0,776

F1 en CV repetida (15 evaluaciones)

Especificación

- **Variable clave:** el ingreso de cada persona, predicho con lo que el test sí trae y sumado al hogar (1.324 variables en total).
- **Algoritmo:** LightGBM (76 %) mezclado con dos redes (19 %) y un rediseño desde cero (5 %); pesos elegidos fuera de muestra.
- **Regla:** pobre si $P(\text{pobre}) \geq 0{,}36$.

Mensajes

1. Las variables aportaron **9 veces más** F1 que los algoritmos.
2. El techo ($\approx 0{,}78$) viene sobre todo de la información que falta.
3. Excluye al 18 % de los pobres, casi todos cerca de la línea.

F1: media armónica de precisión y recall de la clase pobre. Holdout: 20 % del train nunca usado para decidir. Fuente: views/tablas/nivel7/etapa18_resumen.csv.



Qué decir (1 min). Nuestro mejor modelo clasifica hogares pobres con F1 de 0,782 en datos que nunca usamos para decidir. La pieza clave no es el algoritmo sino una variable: predecimos cuánto gana cada persona con lo que el test sí trae (ocupación, horas, cotización) y lo sumamos al hogar. Tres mensajes: las variables pesan 9 veces más que el algoritmo, hay un techo que viene de los datos y los errores se concentran cerca de la línea.

Pregunta difícil: ¿por qué una mezcla y no un solo modelo? La mezcla gana +0,0007 en CV repetida frente a LightGBM solo. El IC ingenuo [+0,0002; +0,0012] excluye cero; el corregido por dependencia entre folds no. Es una mejora marginal: en la práctica LightGBM solo rinde igual.

El test no trae ingresos: hay que inferir la pobreza sin ver su definición

Universidad de los Andes

Intuición. Un hogar es pobre si su ingreso per cápita está bajo la línea de pobreza de su ciudad y mes. El test no trae ningún ingreso.

- 79 variables solo existen en train, entre ellas todos los ingresos.
- Pobre $\Leftrightarrow$ ingreso per cápita $<$ línea, sin excepciones.
- Bogotá está en train pero no en test.

Métrica. "Nadie es pobre" acierta en el 80 % de los hogares, pero tiene F1 $= 0$. El F1 combina **filtración** (no pobres atendidos) y **subcobertura** (pobres excluidos).

164.960

hogares en train

66.168

hogares en test

20,0 %

hogares pobres

El problema es reconstruir el ingreso con lo que sí se observa.

Fuente: views/tablas/nivel7/forense_resumen.csv; views/tablas/desbalance_clases.csv.

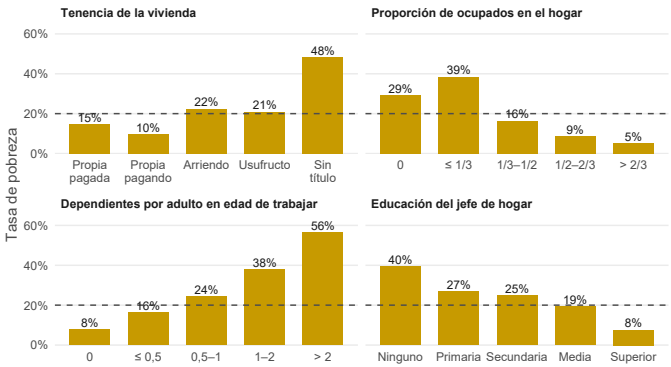


Qué decir. La definición de pobreza es mecánica: ingreso per cápita contra la línea. El reto es que el test no trae ingresos, así que hay que inferirlos de lo observable. La clase pobre es una de cada cinco; por eso no usamos accuracy sino F1, que castiga tanto dejar pobres por fuera (subcobertura) como incluir no pobres (filtración).

Pregunta difícil: ¿por qué no predecir el ingreso y aplicar la línea? El enunciado pide clasificación. Usamos el ingreso solo como objetivo auxiliar por persona, nunca como predictor; el clasificador final predice la etiqueta.

La teoría acierta: trabajo, dependencia, educación y vivienda predicen la pobreza

Tasa de pobreza en train (164.960 hogares). Línea punteada: promedio (20,0%)

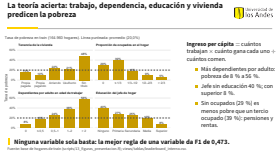


Ingreso per cápita = cuántos trabajan × cuánto gana cada uno ÷ cuántos comen.

- Más dependientes por adulto: pobreza de 8 % a 56 %.
- Jefe sin educación 40 %; con superior 8 %.
- Sin ocupados (29 %) es menos pobre que un tercio ocupado (39 %): pensiones y rentas.

Ninguna variable sola basta: la mejor regla de una variable da F1 de 0,473.

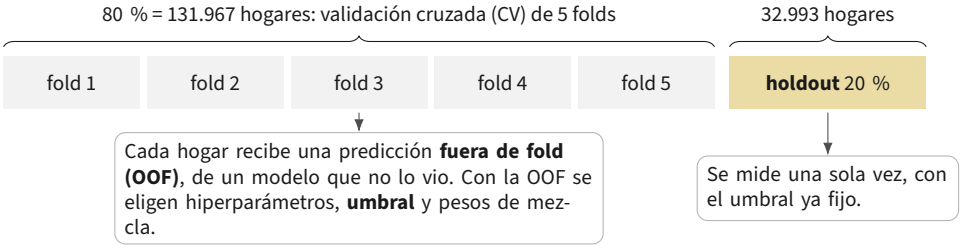
Fuente: base de hogares de train (scripts/13_figuras_presentacion.R); views/tablas/leaderboard_interno.csv.



Qué decir. Partimos de la identidad del ingreso: cuántos trabajan, cuánto gana cada uno y entre cuántos se reparte. Los datos confirman cada pieza. Un patrón rompe el prior: los hogares sin ocupados no son los más pobres, porque muchos viven de pensiones o rentas. La relación no es lineal.

Pregunta difícil: ¿basta con estas variables en un Logit? No: un Logit con 5 variables teóricas da F1 de 0,457, por debajo de la mejor regla de una variable (0,473). Con 48 variables construidas desde las personas sube a 0,718.

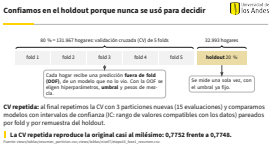
Confiamos en el holdout porque nunca se usó para decidir



CV repetida: al final repetimos la CV con 3 particiones nuevas (15 evaluaciones) y comparamos modelos con intervalos de confianza (IC: rango de valores compatibles con los datos) pareados por fold y por remuestra del holdout.

La CV repetida reproduce la original casi al milésimo: 0,7752 frente a 0,7748.

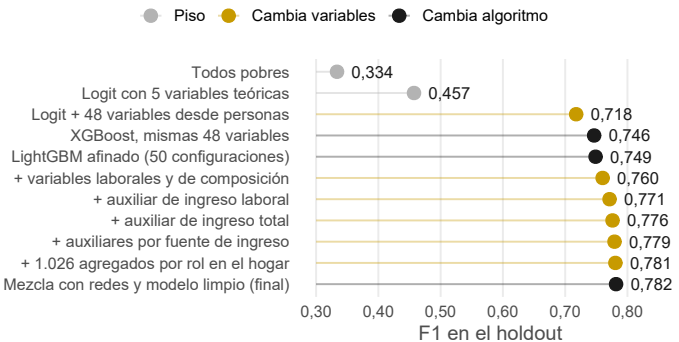
Fuente: views/tablas/resumen_particion.csv; views/tablas/nivel7/etapa16_fase1_resumen.csv.



Qué decir. Apartamos un 20 % al inicio y no lo tocamos. Todo lo que se elige (hiperparámetros, umbral, pesos) se elige con predicciones fuera de fold: cada hogar es predicho por un modelo que no lo vio. Al final repetimos la validación con tres particiones nuevas para medir cuánto ruido hay en una diferencia.

Pregunta difícil: ¿no se sobreajustó el holdout tras muchas etapas? Lo miramos muchas veces, aunque nunca para elegir parámetros. Por eso la comparación final usa la CV repetida en particiones nuevas, donde el orden de los candidatos se mantiene. Kaggle es la verificación externa.

Las variables aportaron 9 veces más F1 que el cambio de algoritmo



Suma de los saltos

- **Variables**: $+0{,}292$.
- **Algoritmo**: $+0{,}032$.

El salto mayor ($0{,}457 \rightarrow 0{,}718$) es el mismo Logit con variables construidas desde las personas.

Rinde más entender el hogar que cambiar de algoritmo.

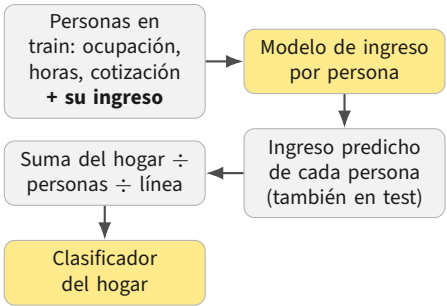
F1 en holdout. Fuente: views/tablas/leaderboard_interno.csv y nivel7/ (ablacion_etapa1, resumen_etapa2, etapa6_ablacion, etapa7_a, etapa18_resumen).



Qué decir. Cada punto es un paso de la escalera, medido en el mismo holdout. Los amarillos cambian las variables con el algoritmo fijo; los negros cambian el algoritmo con las variables fijas. Las variables suman 0,29 de F1; los algoritmos, 0,03.

Pregunta difícil: ¿la descomposición depende del orden? Sí, es secuencial. Pero el contraste se sostiene en ambos sentidos: con 48 variables, pasar de Logit a XGBoost suma 0,029; con LightGBM fijo, pasar de 48 variables a la base final suma 0,032; y otros algoritmos sobre la base final quedan entre 0,767 y 0,779.

El salto clave: predecir el ingreso de cada persona y sumarlo al hogar

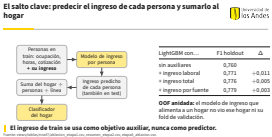


LightGBM con…	F1 holdout	Δ
sin auxiliares	0,760	
+ ingreso laboral	0,771	+0,011
+ ingreso total	0,776	+0,005
+ ingreso por fuente	0,779	+0,003

OOF anidada: el modelo de ingreso que alimenta a un hogar no vio ese hogar ni su fold de validación.

El ingreso de train se usa como objetivo auxiliar, nunca como predictor.

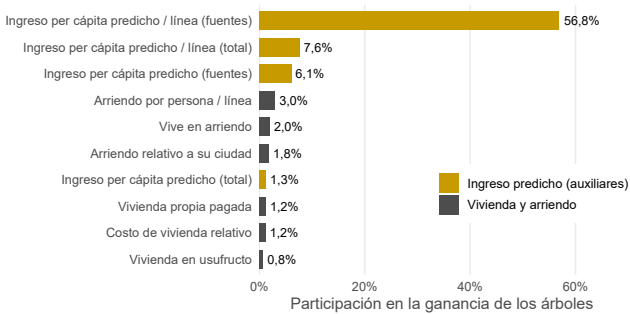
Fuente: views/tablas/nivel7/ablacion_etapa1.csv, resumen_etapa2.csv, etapa6_ablacion.csv.



Qué decir. En train sabemos cuánto gana cada persona. Entrenamos un modelo que predice ese ingreso con lo que el test sí trae. En test lo aplicamos, sumamos las predicciones del hogar y las dividimos por personas y por la línea. Solo el ingreso laboral predicho suma más de un punto de F1.

Pregunta difícil: ¿no es fuga de información? No, por construcción: cada hogar recibe la predicción de un modelo que no lo vio, y dentro de cada fold el auxiliar tampoco vio el fold de validación. Lo verifican tests automáticos. Con las 1.306 variables observadas, un clasificador no distingue train de test (AUC 0,501); con los auxiliares sube a 0,713 porque en test se calculan con ajuste completo y en train fuera de fold.

El modelo decide con el ingreso predicho y con la vivienda



Familia	Vars.	Ganancia
Ingreso predicho	17	75,6 %
Vivienda y arriendo	15	11,2 %
Agregados por rol	1.026	9,1 %
Resto	266	4,0 %

En un boosting interpretable (EBM), la interacción más fuerte es arriendo por persona × vivienda propia pagada.

El modelo reconstruye el ingreso y lo ajusta por el costo de la vivienda.

Ganancia: reducción de la pérdida atribuida a cada variable en LightGBM (76 % de la mezcla). Fuente: views/tablas/nivel7/etapa7_a_importancia.csv, etapa15_ebm_importancia.csv.



Familia	Vars.	Ganancia
Ingreso predicho	17	75,6 %
Vivienda y arriendo	15	11,2 %
Agregados por nil	1.026	9,1 %
Resto	266	4,0 %

En un boosting interpretable (EBM), la interacción más fuerte es arriendo por persona × vivienda propia pagada.

Qué decir. Tres cuartas partes de lo que aprende el modelo vienen de 17 variables de ingreso predicho. Le sigue la vivienda: arriendo frente a la línea y tenencia. El arriendo revela capacidad de pago, y vivir en casa propia pagada es un ingreso implícito.

Pregunta difícil: la ganancia favorece variables continuas. Sí puede sesgar. Por eso lo contrastamos con un EBM, que mide el aporte medio al log-odds: también mandan el ingreso total predicho (0,57) y el arriendo por persona (0,50).

Los hiperparámetros importaron poco; el desbalance, nada

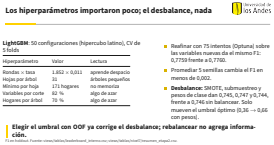
LightGBM: 50 configuraciones (hipercubo latino), CV de 5 folds

Hiperparámetro	Valor	Lectura
Rondas × tasa	1.852 × 0,011	aprende despacio
Hojas por árbol	31	árboles pequeños
Mínimo por hoja	171 hogares	no memoriza
Variables por corte	82 %	algo de azar
Hogares por árbol	70 %	algo de azar

- Reafinar con 75 intentos (Optuna) sobre las variables nuevas da el mismo F1: 0,7759 frente a 0,7760.
- Promediar 5 semillas cambia el F1 en menos de 0,002.
- **Desbalance:** SMOTE, submuestreo y pesos de clase dan 0,745, 0,747 y 0,744, frente a 0,746 sin balancear. Solo mueven el umbral óptimo (0,36 → 0,66 con pesos).

Elegir el umbral con OOF ya corrige el desbalance; rebalancear no agrega información.

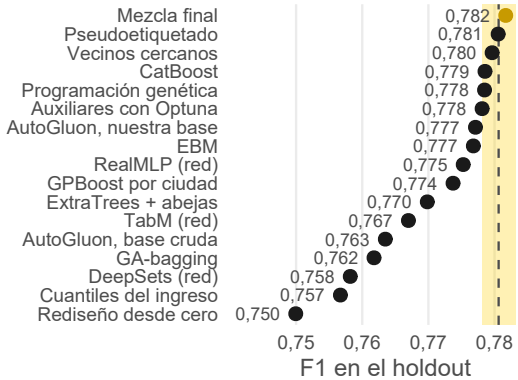
F1 en holdout. Fuente: views/tablas/leaderboard_interno.csv; views/tablas/nivel7/resumen_etapa2.csv.



Qué decir. La configuración ganadora es conservadora: muchos árboles pequeños, aprendizaje lento y hojas de al menos 171 hogares. Buscar de nuevo con 75 intentos no mejora. Rebalancear cambia la escala de las probabilidades, pero como el umbral se elige maximizando F1, el resultado es el mismo.

Pregunta difícil: ¿por qué no tunear con el holdout? Porque dejaría de ser una medida limpia. Todo el tuning usa F1 fuera de fold sobre el 80 %.

Dieciséis alternativas chocan con el mismo techo



Efecto mínimo detectable: la mejora más pequeña que el holdout distingue del ruido es $\pm 0{,}0025$ (banda amarilla alrededor de LightGBM base, línea punteada).

- Ningún algoritmo nuevo supera a LightGBM.
- La mezcla final gana $+0{,}0007$ en CV repetida, IC 95 % $[+0{,}0002; +0{,}0012]$. Corrigiendo por la dependencia entre folds, el IC incluye cero.

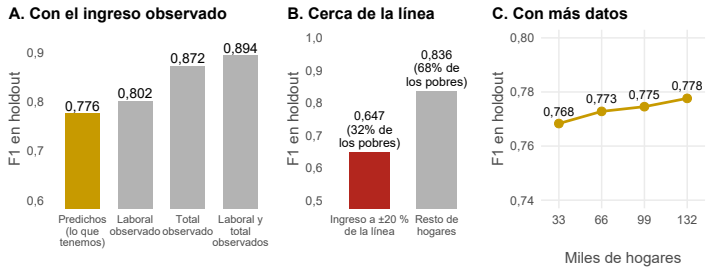
Las mejoras posibles están por debajo de lo que los datos permiten detectar.

F1 en holdout. Fuente: views/tablas/nivel7/ (etapa7_b, etapa8 a etapa18); efecto mínimo de etapa16_fase1_resumen.csv.


Dieciséis alternativas chocan con el mismo techo
Universidad de los Andes
Mezcla final
Pseudoetiquetado
Vecinos cercanos
GPBoost
Programación genética
Auditanes con Optuna
AutoGluon, nuestra base
Ridge
RealMLP (red)
GPBoost por ciudad
LightGBM (red)
Tabbl (red)
AutoGluon, base cruda
TabM (red)
Diseñadas (red)
Cuentas de cruces
Rediseño desde cero
0.780
0.780
0.779
0.779
0.777
0.777
0.7
0.7
0.7

El techo está en los datos: sin el ingreso, un tercio de los pobres es indistinguible

Universidad de los Andes



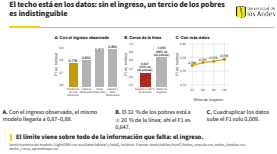
A. Con el ingreso observado, el mismo modelo llegaría a 0,87–0,89.

B. El 32 % de los pobres está a $\pm$ 20 % de la línea; ahí el F1 es 0,647.

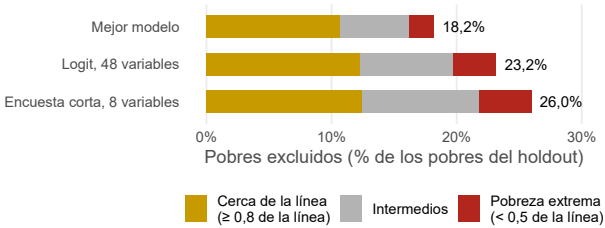
C. Cuadruplicar los datos sube el F1 solo 0,009.

El límite viene sobre todo de la información que falta: el ingreso.

Versión previa del modelo (LightGBM con auxiliares laboral y total), holdout. Fuente: views/tablas/nivel7/techo_oraculo.csv, techo_bandas.csv, techo_curva_aprendizaje.csv.


El techo está en los datos: sin el ingreso, un tercio de los pobres es indistinguible
Universidad de los Andes
A. Con el ingreso observado
B. Cerca de la línea
C. Con más datos
F1 (mean)
0.736
0.832
0.927
1.000
0.647
0.650
0.650
0.650

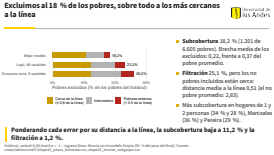
Excluimos al 18 % de los pobres, sobre todo a los más cercanos a la línea



- **Subcobertura** 18,2 % (1.201 de 6.605 pobres). Brecha media de los excluidos: 0,22, frente a 0,37 del pobre promedio.
- **Filtración** 25,1 %, pero los no pobres incluidos están cerca: distancia media a la línea 0,51 (el no pobre promedio: 2,83).
- Más subcobertura en hogares de 1 y 2 personas (34 % y 28 %), Manizales (36 %) y Pereira (29 %).

Ponderando cada error por su distancia a la línea, la subcobertura baja a 11,2 % y la filtración a 1,2 %.

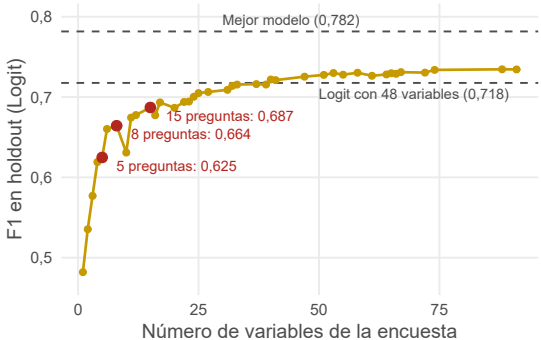
Holdout, umbral 0,36; brecha = 1 − ingreso/línea. Mezcla sin el modelo limpio (95 % del peso del final). Fuente: views/tablas/nivel7/etapa15_pesos_bienestar.csv, etapa15_errores_subgrupo.csv.



Qué decir. El F1 trata igual todos los errores, pero no cuestan lo mismo. El 59 % de los pobres que dejamos fuera tiene ingreso de al menos 0,8 veces la línea, y los no pobres incluidos también están cerca. Ponderando cada error por su distancia a la línea, la subcobertura baja de 18 a 11 %.

Pregunta difícil: ¿hay sesgo contra hogares pequeños? Sí hay más subcobertura en hogares de 1 y 2 personas: su ingreso depende de una sola persona y es más difícil de predecir. Una agencia podría fijar un umbral más bajo para ese grupo.

Una encuesta corta excluye a más pobres, y a más pobres extremos

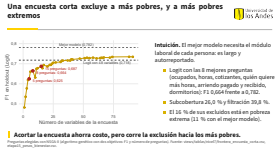


Intuición. El mejor modelo necesita el módulo laboral de cada persona: es largo y autorreportado.

- Logit con las 8 mejores preguntas (ocupados, horas, cotizantes, quién quiere más horas, arriendo pagado y recibido, dormitorios): F1 0,664 frente a 0,782.
- Subcobertura 26,0 % y filtración 39,8 %.
- El 16 % de sus excluidos está en pobreza extrema (11 % con el mejor modelo).

Acortar la encuesta ahorra costo, pero corre la exclusión hacia los más pobres.

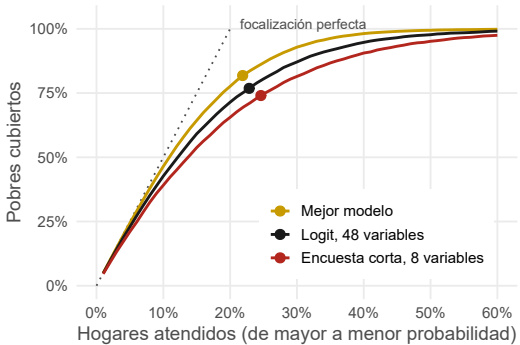
Preguntas elegidas con NSGA-II (algoritmo genético con dos objetivos: F1 y número de preguntas). Fuente: views/tablas/nivel7/frontera_encuesta_corta.csv, etapa15_pesos_bienestar.csv.



Qué decir. Buscamos el mejor conjunto de preguntas para cada tamaño de encuesta. Con 8 preguntas el F1 baja de 0,78 a 0,66, y lo más grave es a quiénes excluye: la exclusión se corre hacia la pobreza extrema.

Pregunta difícil: ¿no pueden usar el modelo de ingreso en la encuesta corta? No sin el módulo laboral: el auxiliar se alimenta de la ocupación, horas y cotización de cada persona. Por eso la frontera se construyó sin auxiliares.

El umbral es una decisión de política: la agencia puede comprar cobertura



El umbral que maximiza F1 supone que ambos errores cuestan igual.

- Atendiendo al 25 % de los hogares se cubre al 86,8 % de los pobres; al 30 %, al 92,9 %.
- Bajar el umbral de 0,38 a 0,21 reduce la subcobertura de 19,3 % a 9,7 %; la filtración sube de 26,5 % a 36,2 % y el F1 apenas cae (0,769 a 0,747).
- La encuesta corta necesita atender al 40 % para cubrir al 90,6 %.

Si excluir a un pobre cuesta más que incluir a un no pobre, conviene bajar el umbral.

Puntos: umbral elegido con OOF. Fuente: views/tablas/nivel7/etapa15_curva_cobertura.csv (holdout); views/tablas/escenarios_politica_n7.csv (OOF de la versión previa con auxiliares laboral y total).



Qué decir. El F1 pondera igual los dos errores. Una agencia que valora más no dejar pobres por fuera puede bajar el umbral: la subcobertura se reduce a la mitad con 10 puntos más de filtración. Como los filtrados están cerca de la línea, ese costo es bajo en bienestar.

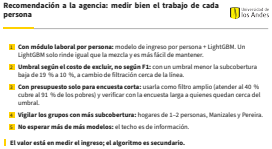
Pregunta difícil: ¿qué umbral recomiendan? Depende del costo relativo que fije la política. Con costos iguales, el del F1; si excluir cuesta el doble, uno más bajo. Es una decisión normativa, no estadística.

Recomendación a la agencia: medir bien el trabajo de cada persona

Universidad de los Andes

1. **Con módulo laboral por persona:** modelo de ingreso por persona + LightGBM. Un LightGBM solo rinde igual que la mezcla y es más fácil de mantener.
2. **Umbral según el costo de excluir, no según F1:** con un umbral menor la subcobertura baja de 19 % a 10 %, a cambio de filtración cerca de la línea.
3. **Con presupuesto solo para encuesta corta:** usarla como filtro amplio (atender al 40 % cubre al 91 % de los pobres) y verificar con la encuesta larga a quienes quedan cerca del umbral.
4. **Vigilar los grupos con más subcobertura:** hogares de 1–2 personas, Manizales y Pereira.
5. **No esperar más de más modelos:** el techo es de información.

El valor está en medir el ingreso; el algoritmo es secundario.



Qué decir. Cinco recomendaciones que se siguen de la evidencia: el modelo sirve si se puede preguntar por el trabajo de cada persona; el umbral es una decisión de política; una encuesta corta funciona como primer filtro si se acepta más filtración; hay grupos que vigilar; y el límite es de información.

Pregunta difícil: ¿son verificables las variables clave? En parte. Tenencia y arriendo se pueden observar en una visita; horas e ingresos son autorreportados. Por eso recomendamos verificar en campo a los hogares cercanos al umbral, donde el modelo es menos confiable.

Glosario (1/2): métricas y errores

Precisión	De los hogares que el programa atiende, qué parte es pobre. 1−precisión = **filtración**: no pobres que reciben el beneficio.
Recall	De los hogares pobres, qué parte atiende el programa. 1−recall = **subcobertura**: pobres excluidos.
F1	Media armónica de precisión y recall: solo es alta si ambas lo son. No premia a los no pobres bien clasificados.
Umbral	Probabilidad a partir de la cual un hogar se clasifica como pobre. Bajarlo cubre más pobres a cambio de más filtración.
IC 95 %	Rango de valores compatibles con los datos. Si el IC de una diferencia incluye cero, no podemos afirmar que haya mejora.
Efecto mínimo detectable	La mejora más pequeña que el diseño detectaría con probabilidad 0,8.

Glosario (1/2): métricas y errores

Universidad de los Andes

Precisión	De los hogares que el programa atiende, qué parte es pobre. 1 − precisión ::: **filtración**: no pobres que reciben el beneficio.
Recall	De los hogares pobres, qué parte atiende el programa. 1 −recall ::: **subcobertura**: pobres excluidos.
F1	Media armónica de precisión y recall: solo es alta si ambas lo son. No premia a los no pobres bien clasificados.
Umbral	Probabilidad a partir de la cual un hogar se clasifica como pobre. Bajarlo cubre más pobres a cambio de más filtración.
IC 95 %	Rango de valores compatibles con los datos. Si el IC de una diferencia incluye cero, no podemos afirmar que haya mejora.
Efecto mínimo detectable	La mejora más pequeña que el diseño detectaría con probabilidad 0,8.

Glosario de apoyo; se muestra solo si lo preguntan.

Glosario (2/2): validación y variables

Holdout	20 % del train (32.993 hogares) apartado al inicio; solo se usa para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques (folds): se entrena con 4 y se evalúa en el quinto, rotando.
Fuera de fold (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella se eligen umbral, pesos e hiperparámetros.
CV repetida	La validación cruzada repetida con 3 particiones nuevas: 15 evaluaciones para medir la variabilidad.
Auxiliar de ingreso	Modelo que predice el ingreso de cada persona con variables que el test sí trae; sumado al hogar, entra como variable.
OOF anidada	El auxiliar que alimenta a un hogar no vio ese hogar ni su fold de validación: así no se filtra la respuesta.

Glosario (2/2): validación y variables

Universidad de los Andes

Holdout	20 % del train (32.993 hogares) apartado al inicio; solo se usa para medir, nunca para decidir.
Validación cruzada	El 80 % restante se parte en 5 bloques (folds): se entrena con 4 y se evalúa en el quinto, rotando.
Fuera de fold (OOF)	La predicción de cada hogar hecha por un modelo que no lo vio. Con ella se eligen umbral, pesos e hiperparámetros.
CV repetida	La validación cruzada repetida con 3 particiones nuevas: 15 evaluaciones para medir la variabilidad.
Auxiliar de ingreso	Modelo que predice el ingreso de cada persona con variables que el test sí trae; sumado al hogar, entra como variable.
OOF amistad	El auxiliar que alimenta a un hogar no visto ese hogar ni su fold de validación: así no se filtra la respuesta.

Glosario de apoyo; se muestra solo si lo preguntan.

Apéndice: auditoría de los datos, sin fuga ni errores de construcción

Universidad de los Andes

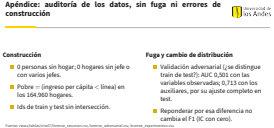
Construcción

- 0 personas sin hogar; 0 hogares sin jefe o con varios jefes.
- Pobre $=$ (ingreso per cápita $<$ línea) en los 164.960 hogares.
- Ids de train y test sin intersección.

Fuga y cambio de distribución

- Validación adversarial (¿se distingue train de test?): AUC 0,501 con las variables observadas; 0,713 con los auxiliares, por su ajuste completo en test.
- Reponderar por esa diferencia no cambia el F1 (IC con cero).

Fuente: views/tablas/nivel7/forense_resumen.csv, forense_adversarial.csv, forense_experimentos.csv.



Respaldo para preguntas sobre fuga o cambio de distribución.

Apéndice: en CV repetida ninguna alternativa mejora de forma detectable

Candidato	F1 CV repetida (EE)	Δ vs. LightGBM [IC 95 %]	F1 holdout [IC 95 %]
LightGBM base	0,7752 (0,0008)		0,7806 [0,7731; 0,7885]
+ redes (mezcla sin limpio)	0,7758 (0,0008)	+0,0006 [−0,0001; +0,0013]	0,7820 [0,7743; 0,7897]
+ redes + limpio (final)	**0,7759 (0,0008)**	+0,0007 [+0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
CatBoost	0,7722 (0,0007)	−0,0030 [−0,0042; −0,0018]	0,7786 [0,7707; 0,7864]
Base con códigos corregidos	0,7754 (0,0008)	+0,0002 [−0,0002; +0,0005]	0,7797 [0,7720; 0,7875]
Rediseño desde cero	0,7478 (0,0008)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

IC pareados ingenuos (15 pares). Con la corrección de Nadeau y Bengio el IC del modelo final es [−0,0004; +0,0017]. Fuente: views/tablas/nivel7/etapa16_fase1_resumen.csv, etapa18_resumen.csv.

Apéndice: en CV repetida ninguna alternativa mejora de forma detectable

Universidad de los Andes

Candidato	F1 CV repetida (EE)	Δ vs. LightGBM [IC 95 %]	F1 holdout [IC 95 %]
LightGBM base	0,7752 (0,0009)		0,7806 [0,7731; 0,7880]
+ redes (reacción sin limpieza)	0,7756 (0,0008)		0,7820 [0,7743; 0,7897]
+ redes + limpieza (final)	**0,7759 (0,0008)**	+0,0007 [−0,0002; +0,0012]	0,7817 [0,7742; 0,7894]
Base con clústeres	0,7754 (0,0008)	+0,0002 [−0,0007; +0,0011]	0,7807 [0,7732; 0,7882]
Base con código postal corregido	0,7754 (0,0008)	+0,0002 [−0,0002; +0,0005]	0,7787 [0,7720; 0,7855]
Rediseño desde cero	0,7478 (0,0009)	−0,0274 [−0,0289; −0,0260]	0,7499 [0,7420; 0,7581]

Respaldo: la única diferencia cuyo IC ingenuo excluye cero es la del modelo final, y por milésimas.

Apéndice: un rediseño desde cero llega a 0,750; le falta el ingreso por persona

Universidad de los Andes

- Rehicimos el pipeline sin mirar el trabajo previo: 74 variables de hogar a partir del diccionario del DANE, con los códigos de “no sabe” como faltantes.
- Una variante con el ingreso del hogar como objetivo auxiliar (anidado) no mejora.
- F1 en CV repetida 0,748 y holdout 0,750, frente a 0,775 y 0,781 de LightGBM base; correlación de sus predicciones con LightGBM: 0,94.
- Lo que separa a los dos pipelines es predecir el ingreso de cada persona, no el del hogar.

Fuente: limpio/resultados/; views/tablas/nivel7/etapa18_resumen.csv.

Apéndice: un rediseño desde cero llega a 0,750; le falta el ingreso por persona

Universidad de los Andes

- Rehicimos el pipeline sin mirar el trabajo previo: 74 variables de hogar a partir del diccionario del DANE, con los códigos de "no sabe" como faltantes.
- Una variante con el ingreso del hogar como objetivo auxiliar (amidado) no mejora.
- F1 en CV repetida 0,748 y holdout 0,750, frente a 0,775 y 0,781 de LightGBM base; correlación de sus predicciones con LightGBM: 0,94.
- Lo que separa a los dos pipelines es predecir el ingreso de cada persona, no el del hogar.

Fuente: Empty/mesBadics_rones/labbase/cost/Compact/4_rmse/main.exe

Respaldo: el rediseño confirma que el auxiliar a nivel persona es la pieza clave.